UNIVERSIDADE [NOME]

Bacharelado em Ciências Econômicas

Impactos da Inteligência Artificial no Mercado de Trabalho: uma Revisão Sistemática da Literatura (2013–2025)

Acacio

20 de outubro de 2026

Acacio

Impactos da Inteligência Artificial no Mercado de Trabalho: uma Revisão Sistemática da Literatura (2013–2025)

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciências Econômicas como requisito parcial para obtenção do grau de Bacharel.

Orientador: [Nome do Orientador]

Resumo

Este trabalho examina se o diagnóstico da literatura econômica sobre o impacto da inteligência artificial (IA) no mercado de trabalho mudou com o avanço da IA generativa. Conduz-se uma revisão sistemática, segundo as diretrizes PRISMA 2020, de estudos publicados entre 2013 e meados de 2026 e indexados na Web of Science e na Scopus. De 3.118 registros, 816 estudos foram incluídos e codificados, com apoio de modelos de linguagem na triagem e na extração, quanto ao tipo de evidência, à tecnologia em foco, aos mecanismos do arcabouço de tarefas de Acemoglu e Restrepo, ao sinal do efeito sobre o emprego e ao grupo de qualificação em risco. A fração de estudos que situam o risco na alta qualificação passa de 2,7% entre os publicados até 2022 para 13,6% entre os publicados de 2023 em diante, mas o risco para a baixa qualificação permanece o diagnóstico mais frequente. A mudança acompanha o objeto tecnológico, e não o calendário: o risco para a alta qualificação é a categoria modal entre os estudos sobre IA generativa (48,5%) e é residual e estável entre os estudos sobre robótica e automação, usados como grupo de comparação. O resultado confirma a abordagem de tarefas, pois o risco segue o conteúdo das tarefas que cada tecnologia executa. Outras mudanças, como o horizonte mais curto e o sinal menos negativo, ocorrem também na literatura de robótica e refletem o amadurecimento empírico do campo. O sinal atribuído ao efeito sobre o emprego depende fortemente do tipo de evidência: estudos de exposição ocupacional tendem ao negativo, estudos de firma ao positivo, e modelos teóricos e revisões ao ambíguo. O novo diagnóstico apoia-se, por ora, em medidas de exposição e em revisões, não em efeitos observados. Discutem-se as limitações de cobertura da busca e do uso de modelos de linguagem como extratores.

Palavras-chave: inteligência artificial; IA generativa; mercado de trabalho; emprego; abordagem de tarefas; revisão sistemática.

Abstract

This study examines whether the economic literature's diagnosis of the impact of artificial intelligence (AI) on the labor market has changed with the rise of generative AI. It conducts a systematic review, following the PRISMA 2020 guidelines, of studies published between 2013 and mid-2026 and indexed in Web of Science and Scopus. Out of 3,118 records, 816 studies were included and coded, with language models assisting in screening and extraction, by type of evidence, technology in focus, the mechanisms of the Acemoglu–Restrepo task framework, the sign of the employment effect, and the skill group at risk. The share of studies that locate the risk in high-skill occupations rises from 2.7% among those published up to 2022 to 13.6% among those published from 2023 onward, although risk for low-skill workers remains the most frequent diagnosis. The change follows the technological object rather than the calendar: high-skill risk is the modal category among studies of generative AI (48.5%) and is residual and stable among studies of robotics and automation, which serve as a comparison group. This result supports the task approach, since risk follows the content of the tasks each technology performs. Other changes, such as shorter horizons and a less negative sign, also occur within the robotics literature and reflect the empirical maturing of the field. The sign attributed to the employment effect depends strongly on the type of evidence: occupational exposure studies lean negative, firm-level studies lean positive, and theoretical models and surveys lean ambiguous. The new diagnosis rests, so far, on exposure measures and surveys rather than on observed effects. Limitations regarding search coverage and the use of language models as extractors are discussed.

Keywords: artificial intelligence; generative AI; labor market; employment; task approach; systematic literature review.

Agradecimentos

[Texto livre, escrito ao final.]

Lista de Siglas

API	*Application Programming Interface* (interface de programação de aplicações)
BCB	Banco Central do Brasil
BIS	*Bank for International Settlements* (Banco de Compensações Internacionais)
CBO	Classificação Brasileira de Ocupações
CEPR	Centre for Economic Policy Research
DOI	*Digital Object Identifier* (identificador de objeto digital)
FGV	Fundação Getulio Vargas
IA	inteligência artificial
IC	intervalo de confiança
IPEA	Instituto de Pesquisa Econômica Aplicada
IZA	*Institute of Labor Economics* (*Institut zur Zukunft der Arbeit*)
LLM	*large language model* (grande modelo de linguagem)
ML	*machine learning* (aprendizado de máquina)
MQO	mínimos quadrados ordinários
NBER	National Bureau of Economic Research
OECD	*Organisation for Economic Co-operation and Development* (OCDE)
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*
RBTC	*routine-biased technological change* — mudança técnica enviesada por rotina (D. H. Autor & Dorn, 2013; D. H. Autor et al., 2003)
RDD	*regression discontinuity design* (regressão descontínua)
SBTC	*skill-biased technical change* — mudança técnica enviesada por qualificação (Katz & Murphy, 1992; Tinbergen, 1974)

Sumário

Lista de Siglas **5**

1 Introdução **7**

2 Referencial teórico **10**

2.1 Tecnologia e emprego: um debate de longa duração 10

2.2 O arcabouço Acemoglu–Restrepo: deslocamento, reinstalação e a corrida entre tarefas 13

3 Metodologia **17**

3.1 Desenho da revisão sistemática 17

3.2 Critérios de inclusão e exclusão 18

3.3 Estratégia de busca 19

3.4 Processo de seleção 20

4 Resultados I — Descritivas do corpus **25**

5 Resultados II — Síntese por janela **30**

6 Resultados III — Comparação pré/pós-ChatGPT **32**

6.1 Eixo 1: Quem está em risco 32

6.2 Eixo 2: Qual o mecanismo 34

6.3 Eixo 3: Como se mede 35

6.4 Eixo 4: O que se sabe vs. o que se projeta 35

6.5 Continuidades 36

6.6 Rupturas 36

7 Discussão — o que mudou, por que mudou e quanto se pode confiar **37**

7.1 Data ou objeto? O risco acompanha a tecnologia estudada 37

7.2 A robótica como grupo de comparação 41

7.3 O sinal depende do que se mede 44

7.4 Recomposição do corpus ou mudança de diagnóstico? 46

7.5 Quanto se pode confiar: validade e sensibilidade 48

7.6 Síntese: três proposições 50

8 Considerações finais **50**

1 Introdução

O receio de que as máquinas tornem o trabalho humano dispensável é recorrente na história econômica, mas poucas vezes voltou ao centro do debate público com a intensidade observada após o lançamento do ChatGPT, em 30 de novembro de 2022. A difusão acelerada dos modelos generativos de linguagem reabriu uma pergunta antiga sob uma forma nova: se as ondas anteriores de automação atingiam sobretudo tarefas rotineiras e manuais, a inteligência artificial (IA) contemporânea avança sobre tarefas *cognitivas*, tais como redigir, programar, analisar e sintetizar, antes tidas como reduto seguro do trabalho qualificado. Estimativas de que parcela expressiva das ocupações é tecnicamente suscetível à computadorização (Frey & Osborne, 2017) e, mais recentemente, de que os grandes modelos de linguagem podem afetar metade das tarefas de até 46% das ocupações, inclusive as de alta remuneração, quando se consideram os *softwares* construídos sobre eles (Eloundou et al., 2024), deram a essa inquietação um lastro empírico e a transformaram em objeto de uma literatura econômica em expansão acelerada.

Essa literatura, contudo, não é uníssona. De um lado, a tradição da economia do trabalho construída desde os anos 2000 – a abordagem de tarefas e o arcabouço de Acemoglu e Restrepo (2019) – ensina que o efeito de uma tecnologia sobre o emprego não é um veredito fixo, mas o saldo entre forças opostas: o deslocamento de tarefas, a criação de novas tarefas, a complementaridade que amplia a produtividade e a expansão da demanda agregada.

De outro, a evidência empírica inicial sobre a IA generativa é heterogênea e por vezes surpreendente. Experimentos encontram ganhos de produtividade concentrados nos trabalhadores menos experientes (Brynjolfsson et al., 2025; Noy & Zhang, 2023), sugerindo complementaridade onde se temia substituição.

Ao deslocar, porém, o nível de análise, encontramos resultados distintos. No plano agregado, Kauhanen e Rouvinen (2025), com dados populacionais da Finlândia, não detectaram no curto prazo diferenças significativas de emprego ou de salário entre as ocupações mais e menos expostas à IA generativa. Há, portanto, um descompasso entre os ganhos medidos em experimentos individuais e a ausência de efeitos macroeconômicos relevantes, o que reforça, agora para os modelos generativos, o achado de Acemoglu et al. (2022) sobre a IA preditiva. Ao mesmo tempo, quando se observa as respostas comportamentais, emergem efeitos antecipatórios. Goller et al. (2025) documentaram queda acentuada na procura por formação profissional nas ocupações cognitivas mais expostas, o que reforça a evidência de que o mercado reage à ameaça percebida antes mesmo de seus efeitos se materializarem no emprego.

Além de diferenças de magnitude, encontramos também divergências em relação à direção dos efeitos. A evidência experimental localiza os maiores ganhos – e, por implicação, a maior pressão substitutiva – na base da distribuição de qualificações, ao passo que os

índices de exposição ocupacional e os estudos de escolha de carreira apontam o risco para as tarefas cognitivas de alta qualificação (Eloundou et al., 2024; Goller et al., 2025); e há ainda quem mostre que a própria adoção da tecnologia permanece restringida por trabalho humano qualificado e escasso (Fontanelli et al., 2025). São diagnósticos que divergem, como se argumenta no Capítulo 7, menos por erro do que por medirem objetos distintos – produtividade, emprego, salário ou escolha ocupacional –, em unidades e horizontes também distintos.

O resultado é um campo vasto, disperso e de diagnósticos não convergentes, em que coexistem a tese da polarização herdada da era da automação e a conjectura de que a IA generativa deslocaria o risco para o topo da distribuição de qualificações. É essa tensão que motiva a presente revisão.

A pergunta central que organiza este trabalho é: *qual foi o efeito do avanço da IA generativa sobre o diagnóstico da literatura econômica sobre o impacto da inteligência artificial no mercado de trabalho?* Mais especificamente, a revisão examina se a literatura publicada antes do lançamento do ChatGPT, que tendia a situar o risco da automação nas tarefas rotineiras de *baixa* qualificação, foi sucedida por uma literatura que desloca esse risco para as tarefas cognitivas de *alta* qualificação – uma hipótese de ruptura no enquadramento do problema. Subordinam-se a ela perguntas auxiliares sobre quais mecanismos teóricos a literatura mobiliza, como mede os efeitos, em que horizonte temporal se situa e qual o sinal predominante que atribui ao saldo de empregos, e sobre se esses traços se alteram de forma sistemática entre os dois períodos.

O objetivo geral é **mapear e sintetizar sistematicamente a literatura econômica sobre os impactos da IA no mercado de trabalho publicada entre 2013 e meados de 2026, comparando o enquadramento do problema antes e depois da difusão da IA generativa**. Desse objetivo decorrem os seguintes objetivos específicos:

1. caracterizar o corpus de estudos quanto a volume, evolução temporal, tipo de evidência, tecnologia de IA em foco e atributos metodológicos;

2. ler o corpus longitudinalmente em três janelas tecnológicas — a da automação (2013–2017), a do aprendizado de máquina e *deep learning* (2018–2022) e a da IA generativa (2022–2026) —, identificando como variam os mecanismos teóricos invocados;

3. comparar, dimensão a dimensão, os estudos anteriores e posteriores ao lançamento do ChatGPT, testando a hipótese de deslocamento do risco para a alta qualificação;

4. distinguir continuidades e rupturas entre os dois períodos e avaliar a robustez dos achados a definições alternativas de período, a subconjuntos do corpus e à composição de tipos de estudo;

5. separar, usando os estudos sobre robótica e automação como grupo de comparação, as mudanças associadas ao objeto tecnológico das tendências gerais do campo;

6. discutir as implicações dos achados para uma economia em desenvolvimento como a brasileira.

A justificativa do trabalho é dupla. Em primeiro lugar, há uma lacuna de síntese. A produção sobre IA e trabalho cresceu de forma acelerada e fragmentada, com desenhos empíricos heterogêneos – exercícios de exposição ocupacional, estudos macro e setoriais, experimentos, análises de firmas e de plataformas de trabalho *online* – e vereditos que não convergem. Falta uma revisão sistemática que organize esse material sob uma lente teórica única e verifique, com método explícito e replicável, se o diagnóstico do campo efetivamente se transformou com a IA generativa ou se os paradigmas da era da automação se mantiveram. Esta revisão se propõe a preencher essa lacuna.

Em segundo lugar, diante de um corpus de centenas de estudos e de uma extração padronizada de múltiplas dimensões por trabalho, a revisão adota um desenho narrativo-estruturado. Não se trata, portanto de um trabalho de meta-análise, uma vez que há heterogeneidade de desenhos e baixa comparabilidade das magnitudes reportadas. A comparação pareada pré/pós-ChatGPT, ancorada nos quatro mecanismos do arcabouço de tarefas, oferece um protocolo transparente para distinguir mudança de ênfase de mudança das conclusões dos trabalhos.

Os resultados, antecipados aqui em linhas gerais, respondem à pergunta central de forma afirmativa. A fração de estudos que situam o risco nas ocupações de alta qualificação multiplica-se por cinco entre os períodos, de 2,7% para 13,6%, ainda que o risco para a baixa qualificação permaneça o diagnóstico mais frequente. Essa mudança acompanha o *objeto* tecnológico: entre os estudos sobre IA generativa, o risco para a alta qualificação é a categoria modal (48,5%), ao passo que, entre os estudos sobre robótica e automação, ele é residual e não se altera de um período para o outro. A literatura não mudou de ideia sobre a automação; passou a estudar também uma tecnologia com outro perfil de tarefas, o que confirma, a abordagem de tarefas. Duas ressalvas acompanham o achado. Parte das demais mudanças observadas – o horizonte mais curto, o recuo dos mecanismos de demanda agregada, o sinal menos negativo – ocorre também na literatura de robótica e reflete o amadurecimento empírico do campo. E o novo diagnóstico apoia-se, por ora, em medidas de exposição, revisões e modelos, não em efeitos observados sobre o emprego. Mostra-se, por fim, que o sinal que cada estudo atribui ao efeito da tecnologia depende fortemente do tipo de evidência empregado, o que explica boa parte da aparente falta de convergência do campo.

Além desta introdução, o trabalho organiza-se em nove capítulos. O Capítulo 2 constrói o referencial teórico, percorrendo o caminho que vai da mudança técnica enviesada por qualificação à abordagem de tarefas e ao arcabouço de Acemoglu e Restrepo, cujos quatro mecanismos – deslocamento, reinstalação, complementaridade e demanda agregada – estruturam toda a análise. O Capítulo 3 detalha o desenho da revisão sistemática: os critérios de inclusão, a estratégia de busca, o processo de seleção segundo o protocolo *Preferred*

Reporting Items for Systematic Reviews and Meta-Analyses (PRISMA), o esquema de extração de dados e a avaliação de qualidade.

Os capítulos seguintes apresentam os resultados. O Capítulo 4 caracteriza o corpus; o Capítulo 5 faz a leitura longitudinal por janela tecnológica; e o Capítulo 6, núcleo do trabalho, conduz a comparação pareada entre os períodos anterior e posterior ao ChatGPT, distinguindo continuidades e rupturas. O Capítulo **??** triangula esses achados pela estrutura de citações do campo, e o Capítulo 7 os confronta com o referencial teórico, examinando se o deslocamento do diagnóstico acompanha a data ou o objeto tecnológico dos estudos e quão sensíveis são as conclusões às escolhas metodológicas. O Capítulo **??** discute as implicações para o Brasil, e o Capítulo 8 retoma os principais achados, reconhece as limitações da revisão e aponta direções para pesquisa futura.

2 Referencial teórico

Este capítulo constrói a lente analítica utilizada para leitura do corpus. Partimos do debate de longa duração sobre máquinas e emprego, passamos pelo paradigma da mudança técnica enviesada por qualificação e por seu limite empírico – a polarização do trabalho –, chegamos ao arcabouço de tarefas de Acemoglu e Restrepo (2019), cujos quatro mecanismos estruturam a codificação dos estudos, e termina situando a literatura específica da inteligência artificial e a virada generativa. O objetivo não é esgotar a teoria econômica do progresso técnico, mas fixar com precisão os conceitos – deslocamento, reinstalação, complementaridade e demanda agregada – que reaparecem, já operacionalizados, nos Capítulos 5 e 6, e explicitar a lacuna que a revisão se propõe a examinar.

2.1 Tecnologia e emprego: um debate de longa duração

A preocupação de que as máquinas suprimam o trabalho humano é mais antiga do que a economia como disciplina formal, mas foi Keynes (1930) quem popularizou o conceito que ainda hoje organiza o debate: o *desemprego tecnológico*, isto é, o desemprego decorrente de que a economia descobre como economizar mão de obra num ritmo mais rápido do que o da abertura de novos usos para o trabalho. Keynes tratava o fenômeno como uma disfunção transitória de um processo, no fundo, benigno, qual seja, a elevação secular do padrão de vida. Essa tensão entre um efeito-deslocamento de curto prazo e um efeito-compensação de prazo mais longo atravessa toda a literatura posterior.

A versão mais célebre do alarme veio de Leontief (1983), para quem o papel do trabalho humano tenderia a encolher como encolhera o papel do cavalo na agricultura. A analogia representa a hipótese de que, a partir de certo ponto, a substituição deixaria de ser compensada. A história econômica, contudo, não confirmou a previsão pessimista. Como sintetiza D. H. Autor (2015), ao longo do século XX a automação eliminou tarefas em

larga escala sem produzir desemprego tecnológico persistente, porque operou em paralelo a forças que ampliaram a demanda por trabalho, isto é, a complementaridade entre máquinas e trabalhadores nas tarefas não automatizadas, o aumento de produtividade e renda e a criação de novas ocupações. O problema teórico relevante, portanto, não foi se a tecnologia destrói postos, mas qual o saldo entre destruição e criação e como ele se distribui entre os trabalhadores. É essa indeterminação que o restante do capítulo procura organizar conceitualmente, e que os resultados encontram, no agregado, como um sinal predominantemente ambíguo sobre o emprego (Capítulo 5).

A primeira resposta sistemática da economia do trabalho a essa indeterminação foi a hipótese da *mudança técnica enviesada por qualificação*, ou *skill-biased technical change* (SBTC). Sua intuição remonta à ideia, formalizada por Tinbergen (1974, 1975), de uma "corrida entre educação e tecnologia": o progresso técnico elevaria continuamente a demanda relativa por trabalhadores qualificados, e o prêmio salarial da qualificação dependeria de a oferta de trabalhadores instruídos acompanhar ou não esse ritmo. Katz e Murphy (1992) deram à tese sua forma empírica canônica, explicando a elevação do prêmio universitário nos Estados Unidos a partir dos anos 1980 pela interação entre uma demanda relativa em alta – atribuída à tecnologia, em especial à informática, hipótese que fora levantada por Krueger (1991) – e oscilações na oferta de formados. Os autores observaram que o prêmio salarial da qualificação subia mesmo com o aumento do número de graduados no mercado. Goldin e Katz (2008) estenderam a análise da corrida entre educação e tecnologia para todo o século XX da economia americana.

Acemoglu (2002) consolidou o arcabouço teórico do SBTC, formalizando a ideia de que o progresso técnico pode ser enviesado por qualificação, ou seja, favorecer mais a mão de obra qualificada do que a não qualificada. O modelo de Acemoglu é o ponto de partida para a análise da mudança técnica enviesada por qualificação e seus efeitos sobre a distribuição de renda e emprego. O SBTC se tornou o paradigma dominante para explicar o aumento da desigualdade salarial e a elevação do prêmio da qualificação nas últimas décadas do século XX.

O poder explicativo do SBTC, porém, esbarrou num fato que ele não acomodava bem. A partir dos anos 1990, a estrutura ocupacional de diversas economias desenvolvidas não se deslocou de forma monotônica em favor da alta qualificação, e sim se *polarizou*: cresceram simultaneamente as ocupações de alta remuneração e as de baixa remuneração, enquanto encolhiam as ocupações de remuneração intermediária. D. H. Autor et al. (2006, 2008) documentaram esse padrão para os Estados Unidos e Goos e Manning (2007) para o Reino Unido – os "*lousy and lovely jobs*". Um modelo em que a tecnologia simplesmente favorece "mais qualificação" não prevê o esvaziamento do *meio* da distribuição; era preciso uma teoria que distinguisse não trabalhadores por nível de instrução, mas *tarefas* por seu conteúdo.

Essa teoria veio com a *abordagem de tarefas*. D. H. Autor et al. (2003) propuseram

deslocar a unidade de análise do trabalhador para a tarefa e classificaram as tarefas segundo serem ou não *rotineiras*, isto é passíveis de descrição por regras explícitas. Os autores, no que ficou conhecido, também, como "modelo ALM" – em referência às iniciais dos autores –, propuseram a distinção conceitual entre "habilidades" e "tarefas". As habilidades são atributos do trabalhador, como escolaridade ou experiência, e as tarefas são as unidades de atividade produtiva que precisam ser executadas para gerar um bem ou serviço, como digitar ou interpretar um texto. Os autores defendem que a tecnologia e a computação, em particular, pouco dizem respeito ao estoque de capacidades humanas do trabalhador – suas habilidades –, mas sim ao conteúdo da rotina das atividades. Dessa forma, o modelo ALM propõe uma matriz de classificação das tarefas:

1. Rotineiras Cognitivas: tarefas de escritório que seguem regras explícitas de processamento de dados (por exemplo, escriturários e contabilidade básica);

2. Rotineiras Manuais: atividades fabris repetitivas ou linhas de produção (por exemplo, operários de montagem);

3. Não Rotineiras Cognitivas (ou Abastratas): resolução de problemas complexos, gestão, engenharia, criação (por exemplo, gerentes, cientistas);

4. Não Rotineiras Manuais: atividades que exigem habilidades físicas e manipulação de equipamentos, ou seja, adaptação motora ao ambiente (por exemplo, cuidadores de idosos, garçons).

O modelo ALM formulou a hipótese de que a automação, ao substituir tarefas rotineiras, reduziria a demanda por trabalhadores de qualificação intermediária, enquanto os trabalhadores de alta qualificação, com tarefas não rotineiras analíticas e interativas, e os de baixa qualificação, com tarefas manuais não rotineiras, seriam relativamente poupados. O modelo explicava a polarização do trabalho como resultado da substituição de tarefas rotineiras por tecnologia, sem necessariamente favorecer mais os trabalhadores de alta qualificação do que os de baixa qualificação.

A tecnologia computacional, nessa leitura, substitui de forma barata as tarefas rotineiras – tanto manuais quanto cognitivas – e *complementa* as tarefas não rotineiras, sejam as analíticas e interativas de alta qualificação, sejam as manuais não rotineiras de baixa qualificação, difíceis de codificar. Como as tarefas rotineiras se concentravam justamente nas ocupações de remuneração intermediária, a hipótese da *mudança técnica enviesada por rotina*, ou *routine-biased technological change* (RBTC), explicava de uma só vez por que o meio se esvazia e as duas pontas crescem.

A evidência empírica subsequente sustentou amplamente o mecanismo. D. H. Autor e Dorn (2013) mostraram que as áreas dos Estados Unidos historicamente mais intensivas em tarefas rotineiras foram as que mais se polarizaram, com expansão de empregos de

serviços de baixa qualificação, e Goos et al. (2014) estenderam o resultado a dezesseis países europeus, atribuindo a polarização à combinação de RBTC e *offshoring*. A síntese de referência do programa é Acemoglu e Autor (2011), que formaliza o "*task framework*" e articula qualificações, tarefas e tecnologias num mesmo modelo de oferta e demanda. É dessa tradição que provém o conceito de *polarização* tal como a revisão o codifica: a tese de que o risco da automação recai de forma desigual, concentrando-se nas tarefas rotineiras de menor qualificação. Como mostram os Capítulos 5 e 6, essa continua a ser a categoria modal de polarização no corpus, antes e depois da IA generativa.

2.2 O arcabouço Acemoglu–Restrepo: deslocamento, reinstalação e a corrida entre tarefas

A abordagem de tarefas ganhou sua formulação dinâmica mais influente na série de trabalhos de Daron Acemoglu e Pascual Restrepo, que constitui a espinha dorsal analítica desta revisão. O ponto de partida é distinguir, dentro do progresso técnico, forças com sinais opostos sobre a demanda por trabalho (Acemoglu & Restrepo, 2018, 2019). São quatro os mecanismos que a revisão extrai desse arcabouço e codifica em cada estudo:

Deslocamento (*displacement*): O efeito direto da automação. Quando o capital passa a executar tarefas antes realizadas por trabalhadores, reduz-se a demanda por trabalho e a participação do trabalho na renda. É o canal que captura a "substituição"no sentido clássico e, como mostram os resultados, o mecanismo mais invocado pela literatura em todas as janelas.

Reinstalação (*reinstatement*): A força contrária de mesma natureza. A criação de *novas* tarefas em que o trabalho tem vantagem comparativa. Para Acemoglu e Restrepo (2019), é sobretudo o surgimento de novas tarefas – e não apenas o barateamento das antigas – que sustenta a demanda por trabalho no longo prazo. A "corrida"do título de Acemoglu e Restrepo (2018) é precisamente entre deslocamento e reinstalação.

Complementaridade e produtividade: Mesmo nas tarefas que automatiza, a tecnologia pode baratear a produção, elevar a produtividade e, por essa via, expandir a demanda por trabalho nas tarefas não automatizadas. É o canal pelo qual a IA "amplia capacidades"em vez de apenas substituir, e o que mais cresce na literatura recente (Capítulo 6).

Demanda agregada: O efeito de renda em nível macroeconômico. Ganhos de produtividade que se convertem em maior renda e gasto e, consequentemente, em demanda por trabalho em toda a economia, inclusive em setores não diretamente afetados pela tecnologia. J. E. Bessen (2018) ressalta que a elasticidade da demanda do

setor é decisiva nesse canal: onde a demanda é elástica, a automação que barateia a produção pode *elevar* o emprego setorial, e apenas onde a demanda já está saturada o efeito-deslocamento prevalece.

A virtude do arcabouço é tornar o saldo sobre o emprego uma questão *empírica* sobre a magnitude relativa dessas forças, e não um veredito teórico fixo. Quando o deslocamento supera a reinstalação e os efeitos de produtividade, a participação do trabalho cai e o emprego se contrai; no caso oposto, a tecnologia é trabalho-amistosa. Acemoglu e Restrepo (2020a) estimam, para a robótica industrial nos Estados Unidos, um efeito líquido negativo sobre emprego e salários locais, ilustrando que o deslocamento pode, de fato, predominar; Acemoglu e Restrepo (2022) mostram que boa parte do aumento da desigualdade salarial americana nas últimas décadas é compatível com um deslocamento de tarefas pouco compensado por reinstalação. Acemoglu e Restrepo advertem, por fim, que a *direção* do progresso técnico é endógena: uma automação que apenas corta custos de mão de obra sem criar tarefas – o que chamam de "*so-so automation*-- gera o pior dos mundos para o trabalho, deslocando sem reinstalar nem elevar muito a produtividade (Acemoglu & Restrepo, 2020b). Essa moldura – quatro forças cujo balanço determina o resultado – é a que a revisão aplica, estudo a estudo, para classificar como a literatura concebe o efeito da IA sobre o trabalho.

A revisão fixa o início de sua janela de busca em 2013, e a escolha tem justificativa teórica e empírica. Às vésperas desse marco, a economia do trabalho havia consolidado o arcabouço de tarefas como linguagem dominante e acumulado evidência robusta sobre a automação *clássica* – a informática e a robótica industrial. Graetz e Michaels (2018), analisando dados de dezessete países, estimaram que os robôs industriais elevaram a produtividade sem reduzir o emprego agregado, ao passo que Acemoglu e Restrepo (2020a) chegaram a um saldo local negativo nos Estados Unidos; a coexistência dessas duas leituras define bem o estado da arte herdado. No plano da síntese de amplo alcance, Brynjolfsson e McAfee (2014) popularizaram a tese de uma "segunda era das máquinas"em que a digitalização passaria a afetar também o trabalho cognitivo, e D. H. Autor (2015) ofereceu o contraponto cauteloso, lembrando a persistência histórica do emprego e o papel da complementaridade.

O ano de 2013 marca, ainda, a fronteira a partir da qual o objeto da revisão deixa de ser a automação genérica e passa a incluir a *inteligência artificial* como categoria própria de tecnologia. Não por acaso, é de 2013 a primeira circulação do estudo de Frey e Osborne sobre a suscetibilidade das ocupações à computadorização, discutido adiante. A janela 2013–2025, portanto, não é arbitrária: ela cobre o período em que a IA – primeiro o aprendizado de máquina e o *deep learning*, depois os modelos generativos – se torna o foco explícito da literatura, sem perder de vista o estoque conceitual herdado da era da automação. A justificativa operacional desse recorte é detalhada na metodologia (Capítulo 3); aqui importa registrar que a fronteira temporal acompanha uma fronteira

tecnológica.

A transposição do arcabouço de tarefas para a inteligência artificial enfrenta uma dificuldade específica: ao contrário da automação clássica, cujas tarefas-alvo eram visivelmente rotineiras, a IA contemporânea avança sobre tarefas *não rotineiras* e cognitivas que se supunham protegidas. O esforço de medir essa exposição organiza boa parte da literatura empírica do período. O marco inaugural é Frey e Osborne (2017), que estimou serem cerca de 47% dos empregos nos Estados Unidos de alto risco de computadorização nas duas décadas seguintes – número amplamente debatido e criticado por tratar ocupações inteiras, e não tarefas, como unidade de risco. As medidas posteriores refinaram justamente esse ponto. Brynjolfsson et al. (2018) propuseram avaliar a "*suitability for machine learning*"tarefa a tarefa; Felten et al. (2018, 2021) construíram o índice de exposição ocupacional à IA que os capítulos descritivos identificam no corpus, ligando avanços em capacidades de IA a habilidades ocupacionais; e Webb (2020) usou o texto de patentes para mapear quais tarefas a IA, ao contrário de softwares e robôs anteriores, tende a atingir.

Um achado recorrente dessa geração de estudos é que o perfil de exposição da IA difere do da automação clássica: enquanto robôs e softwares atingiam tarefas rotineiras de qualificação intermediária e baixa, a exposição à IA preditiva tende a alcançar tarefas de qualificação mais alta, invertendo parcialmente o gradiente da RBTC (Felten et al., 2021; Webb, 2020). Em evidência de demanda por trabalho, Acemoglu et al. (2022) examinaram vagas *online* e encontraram, nos estabelecimentos mais expostos à IA, recomposição de tarefas e reformulação de requisitos, sem efeito agregado nítido sobre o emprego até então – um padrão coerente com a ambivalência que a revisão documenta.

A virada decisiva, contudo, é a da *IA generativa*, cuja difusão a partir do lançamento público do ChatGPT em novembro de 2022 organiza a comparação central desta revisão (Capítulo 6). Diferentemente das ondas anteriores, a evidência inicial sobre os modelos generativos é fortemente *experimental* e centrada em produtividade. Noy e Zhang (2023), em experimento controlado de tarefas de escrita profissional, e Brynjolfsson et al. (2025), com dados de atendimento ao cliente em firma real, encontraram ganhos de produtividade concentrados nos trabalhadores *menos* experientes ou de menor desempenho inicial – um efeito de *compressão* que sugere complementaridade, e não apenas substituição. Eloundou et al. (2024), por sua vez, estimaram que os grandes modelos de linguagem têm potencial de afetar parcela substancial das tarefas de *muitas* ocupações, inclusive as de alta remuneração e escolaridade, tratando os *large language model*s (LLMs) como uma tecnologia de propósito geral. Trabalhos como o de Korinek (2023) ilustram, do lado da própria pesquisa econômica, essa penetração da IA em tarefas cognitivas qualificadas. É essa migração do risco – da tarefa rotineira de baixa qualificação para a tarefa cognitiva de alta qualificação – que constitui a hipótese substantiva examinada pela revisão.

A interpretação teórica dessa evidência inicial está longe de ser consensual, e três

leituras disputam o seu sentido. A primeira é cautelosa quanto ao agregado: Acemoglu (2025) estima que, dadas a fração de tarefas efetivamente expostas e as economias de custo observadas, os ganhos macroeconômicos da IA na próxima década serão modestos, e Brynjolfsson (2022) adverte que uma IA concebida para imitar o trabalho humano, em vez de ampliá-lo, tende a substituir sem criar – a "armadilha de Turing", algo similiar à ideia de *so-so automation*. A segunda leitura desloca a pergunta da substituição para a natureza do que é automatizado: Agrawal et al. (2019) tratam a IA como um barateamento da *predição*, cujo efeito sobre o trabalho é ambíguo porque a predição tanto substitui tarefas quanto eleva o valor do julgamento humano que a complementa. A terceira é a mais otimista e a que mais diretamente dialoga com a evidência de compressão: para D. Autor (2024), ao baratear a *expertise*, a IA generativa poderia permitir que trabalhadores de qualificação intermediária executem tarefas antes reservadas a especialistas, revertendo parte da polarização. Essas leituras importam para a revisão por duas razões. Tornam visível que complementaridade e reinstalação não são sinônimos – ganhar produtividade nas tarefas existentes não é o mesmo que criar tarefas novas, e só a segunda sustenta a demanda por trabalho no longo prazo –, distinção que os resultados mostrarão ser empiricamente relevante. E sugerem que a dicotomia entre alta e baixa qualificação, herdada do debate SBTC-RBTC, pode ser estreita para uma tecnologia cujos efeitos mais bem documentados ocorrem *dentro* das ocupações.

O percurso teórico deste capítulo pode ser resumido em três movimentos. O SBTC explicou o prêmio da qualificação mas não a polarização; a abordagem de tarefas explicou a polarização ao deslocar o foco do trabalhador para a tarefa rotineira; e o arcabouço Acemoglu-Restrepo tornou o saldo sobre o emprego uma questão do balanço entre deslocamento, reinstalação, complementaridade e demanda agregada. Sobre esse acúmulo, a literatura específica da IA acrescentou uma conjectura nova e empiricamente aberta: a de que a inteligência artificial – e, sobretudo, a generativa - romperia o padrão herdado da automação ao deslocar o risco para as tarefas cognitivas de *alta* qualificação, antes tidas como complementares à máquina.

Daí decorre a lacuna que a revisão se propõe a examinar. A literatura econômica sobre IA e trabalho cresceu de forma explosiva e dispersa, com desenhos heterogêneos e vereditos não convergentes; falta uma síntese sistemática que verifique se o diagnóstico mudou *de fato* com a chegada da IA generativa ou se a moldura da polarização e do efeito-substituição, herdada da era da automação, sobreviveu à transição. Em termos operacionais, a hipótese de trabalho sustenta que a literatura pré-ChatGPT convergia para a polarização com risco concentrado nas tarefas rotineiras de baixa qualificação, ao passo que a literatura pós-ChatGPT deslocaria esse risco para as tarefas cognitivas de alta qualificação – uma hipótese de *ruptura* testada, dimensão a dimensão, no capítulos de resultados. Os quatro mecanismos definidos n Seção 2 fornecem as categorias dessa codificação; a comparação pareada pré/pós-ChatGPT (Capítulo 6) fornece o teste. A

própria abordagem de tarefas oferece, contudo, uma previsão mais fina do que a simples oposição entre períodos: se o risco segue o conteúdo das tarefas que cada tecnologia executa, o deslocamento do diagnóstico deve aparecer nos estudos cujo *objeto* é a IA generativa, e não nos que seguem estudando robôs e automação, qualquer que seja a data em que foram publicados. Essa implicação é testada no Capítulo 7, usando a literatura de robótica como grupo de comparação. O que se verificará é menos uma inversão do consenso anterior do que um deslocamento parcial do diagnóstico, nítido onde a teoria o prevê e ausente onde ela não o prevê.

3 Metodologia

Este capítulo descreve o desenho e a execução da revisão sistemática que sustenta os achados dos Capítulos 4 a 6. A revisão seguiu um protocolo registrado em controle de versão *antes* da execução da busca, e cada etapa do processamento foi implementada como código determinístico e idempotente, orquestrado por um `Makefile` único. Onde a execução divergiu do protocolo original, o desvio é declarado e justificado, e a versão correspondente do protocolo (v1.0 → v1.2) documenta a emenda. O objetivo desta seção é, portanto, duplo: descrever o método e expor com transparência suas escolhas e limitações, de modo que a revisão seja auditável e reproduzível.

3.1 Desenho da revisão sistemática

A revisão é *sistemática*, no sentido de partir de um protocolo explícito, de critérios de elegibilidade pré-registrados e de um processo de seleção rastreável, e *narrativo-estruturada* na síntese. A opção por não conduzir uma meta-análise decorre da heterogeneidade do corpus (Seção 4): convivem exercícios de exposição ocupacional baseados em índices como o de Felten, estudos de plataformas de trabalho *online*, evidência macro e setorial, modelos teóricos e *surveys*, sem uma medida de efeito comum que justifique o agrupamento estatístico de tamanhos de efeito. Em lugar disso, a extração organiza cada estudo em campos fixos e a síntese compara distribuições de classificações entre janelas temporais e entre os períodos pré e pós-ChatGPT.

O relato segue as diretrizes PRISMA 2020 para a identificação, triagem, elegibilidade e inclusão de estudos, sumarizadas no diagrama da Figura 1. Uma característica distintiva deste desenho é o uso intensivo de modelos de linguagem (LLMs) como instrumentos de triagem, arbitragem e extração. Essa escolha é metodologicamente consequente – substitui, em parte, o trabalho de revisores humanos previsto no protocolo v1.0 – e por isso é tratada explicitamente: cada etapa assistida por LLM tem sua confiabilidade reportada (concordância inter-modelo, κ de Cohen, verificação humana amostral) e suas limitações reconhecidas na Seção **??**.

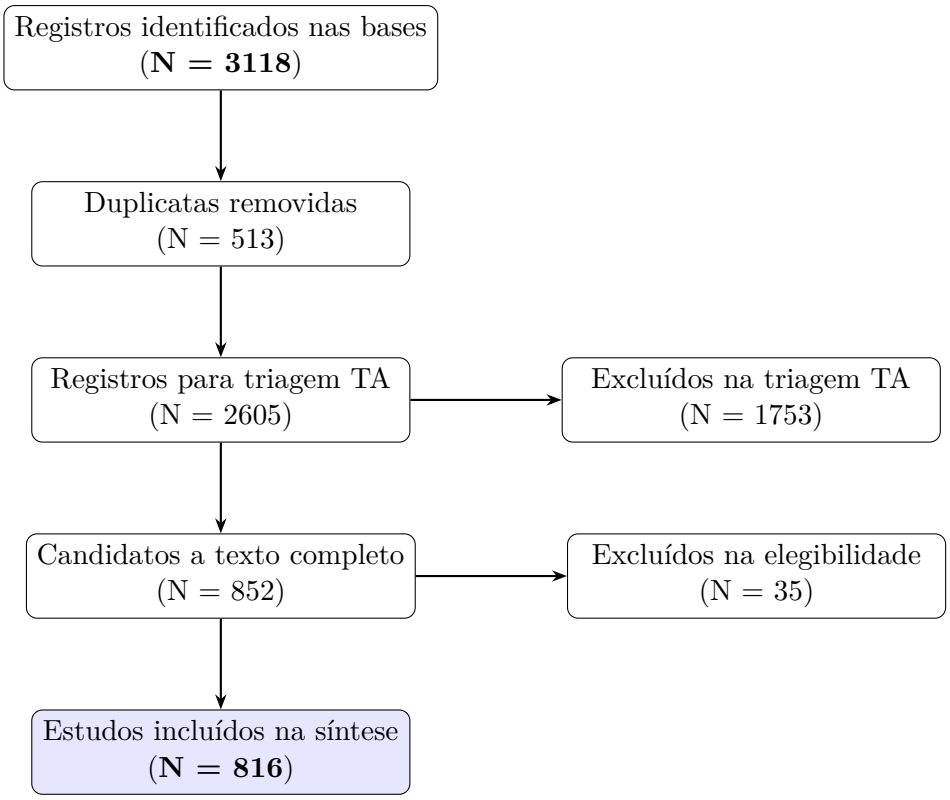


Figura 1: Diagrama PRISMA 2020 do processo de seleção.

3.2 Critérios de inclusão e exclusão

Foram considerados elegíveis estudos publicados entre 1º de janeiro de 2013 e 30 de junho de 2026, em inglês, português, espanhol ou francês, que tratassem do efeito de alguma tecnologia de inteligência artificial – aprendizado de máquina supervisionado ou não-supervisionado, *deep learning*, processamento de linguagem natural, visão computacional, LLMs e IA generativa, ou robôs com componente de IA – sobre o emprego, entendido em sentido amplo: nível de emprego, criação ou destruição de postos, exposição ocupacional ou demanda por trabalho. Quanto ao tipo de publicação, admitiram-se artigos em periódicos revisados por pares, *working papers* de instituições reconhecidas (NBER, IZA, CEPR, BIS, OECD, IPEA, BCB, FGV) e capítulos indexados, sem restrição de foco geográfico.

A exclusão obedeceu a cinco códigos: **E1**, tema fora do escopo (produtividade individual sem ligação com emprego; IA em educação, saúde, ética ou governança sem conexão com o mercado de trabalho); **E2**, tecnologia fora do escopo (robótica industrial pré-IA, automação puramente mecânica, sistemas especialistas legados sem aprendizado); **E3**, tipo de documento inválido (editorial, resenha, opinião, *post* de *blog*, *white paper* sem metodologia, tese não publicada); **E4**, texto completo inacessível; e **E5**, qualidade insuficiente (sem metodologia descrita ou sem evidência verificável). O código E4 não se aplica à triagem por título e resumo, sendo reservado à etapa de texto completo.

Um desvio na aplicação do código E2 precisa ser declarado. O critério excluiria a

robótica industrial e a automação sem componente de aprendizado; na prática, como a *string* de busca inclui o termo "*automation*"e a fronteira entre automação e IA raramente é explícita nos resumos, a triagem conservadora manteve esses estudos, que vieram a compor metade do corpus (413 dos 816 estudos analisados têm a automação ou a robótica como tecnologia em foco). Em vez de removê-los *a posteriori*, a revisão os trata como *grupo de comparação*: por versarem sobre uma tecnologia cujo perfil de tarefas não se alterou com o ChatGPT, permitem distinguir o que mudou na literatura por causa do novo objeto tecnológico do que mudou no campo como um todo (Seção **??**).

O recorte temporal inicia em 2013 por quatro razões registradas no protocolo: a inflexão tecnológica marcada por AlexNet/ImageNet (dezembro de 2012), que abre o ciclo prático do *deep learning*; a inflexão metodológica em economia do trabalho associada a Frey e Osborne (2013) e a Autor (2013), que fornecem o *template* analítico da literatura subsequente; o crescimento exponencial de publicações no nexo IA-trabalho a partir daquele ano; e a necessidade de uma janela pré-2022 longa (cerca de uma década) para tornar coerente a comparação pré/pós-ChatGPT. Antecedentes seminais anteriores a 2013 não entram no corpus sistemático, mas são discutidos no referencial teórico (Capítulo 2). O limite superior, originalmente 31 de dezembro de 2025, foi estendido para 30 de junho de 2026: as bases retornaram centenas de registros datados de 2026 em regime de *early access* – disponibilizados *online* ainda em 2025, mas vinculados a fascículos de 2026 –, que constituem a evidência pós-ChatGPT mais recente e cujo descarte empobreceria a comparação central da revisão.

3.3 Estratégia de busca

A busca foi conduzida na Web of Science e na Scopus, complementadas por referência a periódicos-chave de economia. As *strings* de busca, fixadas em quatro idiomas (`en`, `pt`, `es`, `fr`) e versionadas no protocolo, combinam três blocos por conjunção lógica: termos de tecnologia de IA, termos de mercado de trabalho e termos de efeito ou impacto, cada bloco internamente disjuntivo. A produção indexada pela SciELO é coberta pela Scopus, que incorpora o *SciELO Citation Index*; optou-se por não consultar a SciELO como base autônoma para evitar duplicação e manter um único *pipeline* de exportação em formato BibTeX.

A base OpenAlex, inicialmente prevista como fonte complementar via *Application Programming Interface* (API), foi descartada após teste empírico: seu parâmetro `search` não suporta operadores booleanos AND/OR no lado do servidor, apenas correspondência *full-text* difusa, de modo que a *query* retornava milhões de registros mesmo com filtros de conceito – volume inviável de pós-filtrar com a precisão exigida. A Web of Science e a Scopus, por oferecerem booleano nativo e curadoria temática, foram consideradas suficientes para o escopo. Cada execução gravou, ao lado do arquivo de resultados, um

sidecar de metadados com a versão da *string*, o número de registros e o *hash* SHA-256 do arquivo exportado.

A Tabela 2 resume o resultado da busca e a contribuição de cada base. A Scopus forneceu 2.244 registros e a Web of Science, 874, já descontadas duas duplicatas internas da primeira. Cerca de 95% dos registros trazem DOI e praticamente todos trazem resumo, o que sustenta tanto a deduplicação por DOI quanto a triagem por título e resumo. As bases são mais complementares do que redundantes: 513 registros aparecem em ambas, mas 361 só foram encontrados na Web of Science. Essa complementaridade é ainda mais clara no corpus final. Dos 816 estudos incluídos na síntese, 163 (20,0%) provêm exclusivamente da Web of Science, e a taxa de inclusão de seus registros (53,9%) é quase o dobro da observada na Scopus (29,1%), reflexo de uma cobertura mais seletiva e mais concentrada em periódicos de economia. Uma busca restrita à Scopus teria perdido um quinto do corpus; uma restrita à Web of Science, mais de dois quintos.

Tabela 2: Resultado da busca por base e contribuição para o corpus final.

	Scopus	Web of Science	Total
Registros recuperados	2.244	874	3.118
Presentes em mais de uma base	513	513	513
Registros únicos após deduplicação			2.605
Incluídos na síntese	653	471	816
dos quais exclusivos da base	345	163	508
Taxa de inclusão	29,1%	53,9%	31,3%

3.4 Processo de seleção

Os 3.118 registros consolidados das duas bases passaram por deduplicação em três passes sucessivos: correspondência exata de *Digital Object Identifier* (DOI) normalizado; correspondência por chave composta (sobrenome do primeiro autor, ano e título normalizado), para registros sem DOI; e, por fim, similaridade de *embeddings* de título (*cosine similarity* acima de limiar) sobre os remanescentes sem DOI. Cada remoção foi registrada em *log* com a regra aplicada e o registro mantido. A deduplicação reduziu o conjunto de 3.118 para 2.605 registros únicos.

A triagem dos 2.605 registros foi realizada por dois avaliadores automáticos independentes – Claude Sonnet 4.6 e Claude Haiku 4.5 –, cada qual recebendo o mesmo bloco de critérios (estável e marcado para *prompt caching*) e os dados do registro, e devolvendo uma decisão estruturada (`incluir`, `excluir` ou `duvida`), uma justificativa, um grau de confiança e, quando aplicável, o código de exclusão. As chamadas foram submetidas pela *Message Batches API* da Anthropic, com cache por registro que torna a etapa idempotente.

As decisões dos dois modelos foram combinadas por **união conservadora**: um

registro só é excluído na triagem quando *ambos* os modelos o excluem; em qualquer outra configuração (incluindo dúvidas), o registro segue adiante. A regra prioriza a sensibilidade sobre a especificidade – erra para o lado da inclusão –, coerente com o princípio de que a incerteza se resolve na leitura de texto completo, nunca por exclusão precoce. A concordância inter-modelo é reportada na Tabela 3: κ de Cohen de 0,602 (concordância em 1.992 dos 2.605 casos, 76,5%), valor moderado que evidencia tanto a convergência substantiva dos modelos quanto a existência de uma zona cinzenta relevante. Pela união conservadora, 1.278 registros foram excluídos (os dois modelos concordaram em excluir) e 1.327 seguiram como incluídos, dos quais 462 por inclusão unânime.

Tabela 3: Concordância inter-modelo no screening (κ de Cohen = 0.602; concordância = 1992/2605 = 76.5%)

	Haiku 4.5		
Sonnet 4.6	incluir	excluir	duvida
incluir	462	9	16
excluir	38	1278	214
duvida	226	110	252

Os 865 registros incluídos de forma *não unânime* (decisão final `incluir` sem que ambos os triadores tenham votado `incluir`) – os *soft-includes* – foram encaminhados a um terceiro avaliador, mais capaz e independente: Claude Opus 4.7, operando *cego* (sem acesso aos pareceres dos triadores) e forçado a uma decisão binária (manter ou excluir). O árbitro mantêve 390 e excluiu 475 desses 865 casos. A Tabela 4 reporta a concordância par-a-par entre o árbitro e cada triador nos casos efetivamente arbitrados; a baixa concordância com o Haiku ($\kappa \approx 0$) é esperada e informativa, pois a arbitragem incide justamente sobre os casos em que os triadores divergiam ou hesitavam.

Esta arbitragem por LLM substitui a revisão humana prevista no protocolo v1.0. O desvio decorre de restrição de tempo e escala e é mitigado por três salvaguardas: três modelos independentes, sendo o árbitro o mais capaz e não participante da triagem; a regra conservadora (na incerteza, inclui; falha técnica nunca exclui); e o relato explícito da concordância. A ferramenta de revisão humana permanece disponível como auditoria alternativa. Ao final da triagem e arbitragem, 852 estudos compõem o corpus encaminhado à etapa de texto completo – os 462 de inclusão unânime mais os 390 mantidos pelo árbitro.

Para os 852 estudos, procurou-se obter o PDF de texto completo por duas vias: resolução automática de acesso aberto via Unpaywall e suplemento manual – PDFs depositados manualmente a partir de acesso institucional. Os PDFs foram armazenados em formato nativo, sem extração intermediária de texto: na etapa seguinte o próprio LLM lê o documento nativamente. Estudos sem acesso aberto e sem suplemento manual permaneceram em nível de resumo (`abstract`). A cobertura efetiva de texto completo foi de 14,2% (121 de 852); o restante foi processado a partir do resumo, com a cobertura

Tabela 4: Concordância do árbitro (Opus 4.7) com os triadores nos casos efetivamente arbitrados (n=865; 0 falhas técnicas excluídas do κ e forçadas a incluir; rótulo binário: excluir vs. manter [incluir/duvida])

Par	Concordância	κ de Cohen
Árbitro × Sonnet 4.6	590/865 = 68.2%	0.389
Árbitro × Haiku 4.5	399/865 = 46.1%	-0.006

registrada no manifesto, no PRISMA e nas limitações. Esse desvio em relação à leitura de texto completo prevista no protocolo v1.0 é declarado e tratado na Seção **??**.

A decisão de elegibilidade (aplicação dos códigos E1–E5 ao texto completo, ou ao resumo quando este era a única fonte) e a extração dos campos do esquema foram operacionalizadas em uma passada combinada por Claude Sonnet 4.6, lendo o PDF nativo onde disponível e o resumo no restante. O bloco bibliográfico de identificação (bloco A) é preenchido deterministicamente a partir do corpus, não pelo modelo; ao LLM cabe decidir a elegibilidade e preencher os blocos substantivos. O resultado é `06_extraction.csv`, com uma linha por estudo.

Dos 852 estudos, 817 foram julgados elegíveis e 35 excluídos (27 por E3 e 8 por E5). O corpus efetivamente analisável foi, contudo, de 816 estudos: os 817 elegíveis menos o registro sem extração possível. É sobre esse $N = 816$ que se calculam os percentuais dos capítulos de resultados.

Cada estudo foi codificado segundo um esquema fixo, registrado antes da extração, organizado em sete blocos. O **bloco A** (identificação) reúne DOI, título, autores, ano, periódico, tipo de publicação, país-foco e período dos dados empíricos. O **bloco B** (classificação temporal) atribui a janela (2013–2017, 2018–2022 ou 2022–2026), a posição pré/pós-ChatGPT (pivô em 30 de novembro de 2022) e a tecnologia de IA em foco; a janela e a posição pré/pós usadas na análise são derivadas do ano de publicação, como explica a Seção **??**. O **bloco C** (tipo de evidência) registra o tipo de estudo, o método empírico, a unidade de análise e a fonte de dados. O **bloco D** (mecanismos teóricos) marca, conforme o arcabouço de tarefas de Acemoglu e Restrepo, a presença de deslocamento, reinstalação, complementaridade e demanda agregada. O **bloco E** (achados), analiticamente central, codifica o sinal do efeito sobre o emprego, a magnitude reportada e normalizada, as ocupações afetadas, o padrão de polarização e o horizonte temporal. O **bloco F** (qualidade e robustez) registra o *score* de qualidade, as limitações declaradas, a replicabilidade e a revisão por pares. O **bloco G** (notas) guarda observações livres do extrator e referências cruzadas. Os valores não informados são mantidos explicitamente como tais e ficam fora do denominador das proporções calculadas na síntese.

A comparação central da revisão é entre estudos *publicados* antes e depois do lançamento do ChatGPT. No esquema original, a janela e a posição pré/pós eram preenchidas pelo modelo extrator, com a instrução "pivô 2022-11-30", sem menção explícita à data de

publicação. A auditoria dos resultados mostrou que o modelo interpretou o campo de forma híbrida: 115 estudos publicados entre 2023 e 2026 foram classificados como "pré"porque seus *dados* eram anteriores a 2022, e alguns estudos de 2024–2025 foram alocados à janela 2013–2017. A concordância entre a classificação do modelo e o ano de publicação era de 85,9%. Como a definição declarada é a da publicação, as duas variáveis passaram a ser derivadas de forma determinística do ano de publicação, que integra o bloco A: são "pré"os estudos publicados até 2022 e "pós"os publicados de 2023 em diante; as janelas correspondem a 2013-2017, 2018-2022 e 2023-2026. A granularidade é anual porque as bases não fornecem o mês de publicação de forma confiável; os estudos publicados em dezembro de 2022 ficam, assim, no período pré. A classificação original do modelo é preservada e usada como análise de sensibilidade (Tabela 14), assim como um pivô alternativo em 2024, que acomoda a defasagem editorial entre a redação e a publicação de um artigo.

A qualidade metodológica de cada estudo foi avaliada por uma rubrica de 1 a 5, preliminar na elegibilidade e revisada na extração. A rubrica combina prestígio do veículo, força da estratégia de identificação, presença de testes de robustez e replicabilidade, com um princípio orientador: o *score* reflete o *rigor* do estudo, não a *direção* de seus achados. Um estudo com achado nulo pode receber 5, e um estudo com efeito grande mas identificação fraca pode receber 2. Estudos teóricos são avaliados pela clareza do modelo, pela transparência das premissas e pelo alinhamento com a literatura, segundo rubrica adaptada. O *score* de qualidade sustenta a análise de robustez do Capítulo 6, que verifica se os achados centrais se mantêm ao restringir o corpus aos estudos de maior rigor (*score* ≥ 4).

A síntese opera sobre o corpus analisável ($N = 816$), definido pelo filtro canônico "elegível e com extração bem-sucedida", e se organiza em três camadas, correspondentes aos três capítulos de resultados: descritivas do corpus (Capítulo 4), síntese por janela temporal (Capítulo 5) e comparação pareada pré/pós-ChatGPT (Capítulo 6). Uma quarta camada, de aprofundamento, sustenta a Discussão (Capítulo 7). Todas as figuras e tabelas são geradas por *scripts* a partir do CSV de extração, sem edição manual.

As proporções de cada dimensão são calculadas apenas sobre os estudos que a classificaram – valores não informados ficam fora do denominador. As associações entre período (ou janela) e variáveis categóricas são testadas pelo χ^2 de independência; em tabelas 2×2 com contagens pequenas, recorre-se ao teste exato de Fisher e à razão de chances. Proporções de interesse acompanham intervalo de confiança de 95% calculado pelo método de Wilson. A intensidade das associações é resumida pelo V de Cramér. Na camada de aprofundamento, modelos logit estimam a razão de chances do período controlando a composição do corpus (tipo de evidência, objeto tecnológico, país-foco e qualidade), a tendência temporal é testada por logit sobre o ano de publicação, e a família de testes pré/pós recebe a correção de Holm para comparações múltiplas.

A estratégia de identificação da Discussão apoia-se em três comparações complementares, todas construídas sobre o campo `tecnologia_focada` do bloco B. A primeira cruza a polarização com o objeto tecnológico do estudo, para verificar se o deslocamento do risco acompanha a data ou a tecnologia. A segunda é um *teste placebo*: repete-se a comparação pré/pós apenas entre os estudos de robótica e automação, nos quais, se a mudança decorre do objeto, nenhuma diferença deve aparecer; as diferenças que ainda assim aparecem são lidas como tendências de época, comuns a todo o campo. A terceira confronta diretamente a literatura de robótica com a de IA generativa, restringindo ambas aos estudos publicados de 2023 em diante, de modo a igualar o calendário. Em todas, o ano de publicação é determinístico; a tecnologia em foco e os desfechos são codificados pelo extrator, limitação retomada na Seção **??**. O pivô da comparação pré/pós é 30 de novembro de 2022 (lançamento do ChatGPT).

Todo o *pipeline* – busca, deduplicação, triagem, arbitragem, aquisição de texto, elegibilidade, extração e análise – foi implementado em Python 3.12, com dependências fixadas por *lockfile* (`uv`) e etapas encadeadas por um `Makefile` com alvos explícitos. Os *scripts* são determinísticos e idempotentes: reexecuções não duplicam trabalho nem alteram resultados já calculados, e a recuperação dos estudos pendentes apenas atualiza os números afetados. As fronteiras de entrada e saída de rede (chamadas às bases e à API de LLM) são isoladas atrás de *callables* injetáveis, executados por clientes mock em testes automatizados, de modo que a lógica do *pipeline* é verificável sem custo de API. As chamadas a LLM usam a *Batch API* com *prompt caching* no bloco estável de critérios, e cada resposta é cacheada por registro. Exportações brutas têm *hash* SHA-256 registrado, e cada etapa grava *logs* em `data/processed/`.

As principais limitações desta revisão decorrem das próprias escolhas de viabilização e são declaradas aqui para apreciação crítica.

LLM como juiz e extrator. A triagem, a arbitragem, a elegibilidade e a extração são executadas por modelos de linguagem. A confiabilidade é aferida por κ inter-modelo e pela verificação humana amostral; ainda assim, erros sistemáticos correlacionados entre etapas não podem ser inteiramente descartados.

Cobertura de texto completo. Apenas 14,2% dos estudos foram lidos em texto completo; o restante foi avaliado a partir do resumo, o que pode subdimensionar nuances de método e magnitude – limitação que reaparece na escassez de magnitudes normalizadas discutida no Capítulo 6.

Sensibilidade da busca. Aferida contra as referências mais citadas pelo próprio corpus, a busca recuperou 15 das 46 com data elegível (Capítulo 7). As *strings* não incluem termos como "*robot**"e "*computeri?ation*", e as bases consultadas não indexam *working papers*, embora os critérios de inclusão os admitam: o corpus final não contém nenhum. Trabalhos de fronteira publicados em periódicos de ciência geral ou em séries como a do NBER ficam, por isso, fora do corpus sistemático e entram apenas pelo referencial teórico.

Verificação por revisor único. A validação amostral é feita por um único revisor; mitiga-se com cegueira na elegibilidade e intervalos de Wilson, mas estratos pequenos podem gerar intervalos largos e a auditoria de campos, por mostrar o valor do LLM, pode ancorar o revisor.

Demais limitações. O corpus pós-2022 é jovem e 15% dele corresponde a registros de 2026 em *early access*; a base EconLit não foi acessada (suprida por busca direta em periódicos); e antecedentes seminais anteriores a 2013 ficam fora do corpus sistemático, sendo tratados no referencial teórico.

4 Resultados I — Descritivas do corpus

Este capítulo caracteriza o corpus de análise antes de passar à síntese substantiva. Das 852 entradas que percorreram a extração estruturada, 816 constituem o conjunto efetivamente analisável – estudos marcados como elegíveis e com extração bem-sucedida. Excluem-se 35 registros inelegíveis (27 por tipo de documento inválido, E3, e 8 por qualidade insuficiente, E5) e um único registro cuja resposta do modelo não pôde ser interpretada (*parse fail*). Salvo indicação em contrário, os percentuais deste e dos próximos capítulos têm como base esse $N = 816$, e as proporções de cada dimensão são calculadas apenas sobre os estudos que a classificaram (valores não informados ficam fora do denominador).

A Figura 2 mostra que o corpus se concentra fortemente no período recente: 636 dos 816 estudos (77,9%) foram publicados a partir de 2022, com pico em 2025 (252 estudos) e em 2024 (137); os 123 registros de 2026 correspondem a publicações em *early access*. A produção anterior a 2018 é residual (o estudo mais antigo do corpus é de 2015). Esse perfil é, em si, um primeiro achado: o interesse econômico pela relação entre inteligênciaartificial e emprego acelera acentuadamente após a difusão dos modelos generativos, refletindo tanto o aumento de submissões quanto a janela de busca estendida a meados de 2026.

Agrupando os estudos nas três janelas de interesse (Figura 3), observam-se 15 estudos na janela da automação (2013–2017), 225 na janela de *machine learning* e *deep learning* (2018–2022) e 576 na janela da IA generativa (2022–2026). A janela e a posição pré/pós-ChatGPT são atribuídas de forma determinística pelo ano de publicação (Seção **??**): são pós-ChatGPT os estudos publicados de 2023 em diante. Esta última janela concentra 70,6% do corpus, o que condiciona a leitura comparativa dos capítulos seguintes: o peso da evidência recente é grande, e a comparação pré/pós-ChatGPT deve ser interpretada à luz desse desbalanceamento amostral.

Quanto ao tipo de evidência (Figura 4), predominam os estudos de evidência macro/setorial (218) e as revisões e *surveys* (188), seguidos por trabalhos teóricos e de modelagem (148), estudos de exposição ocupacional (131) e análises de firma ou de plataformas de *freelancers* (125). Uma sexta barra, "indivíduo", reúne seis estudos e merece esclarecimento, pois não corresponde a um tipo de estudo previsto no esquema de extração:

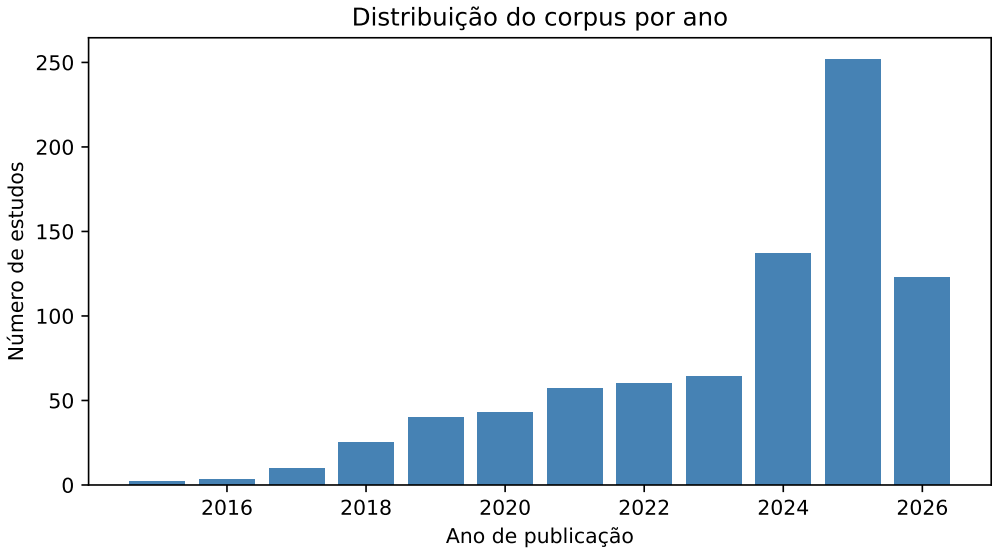


Figura 2: Distribuição do corpus por ano de publicação.

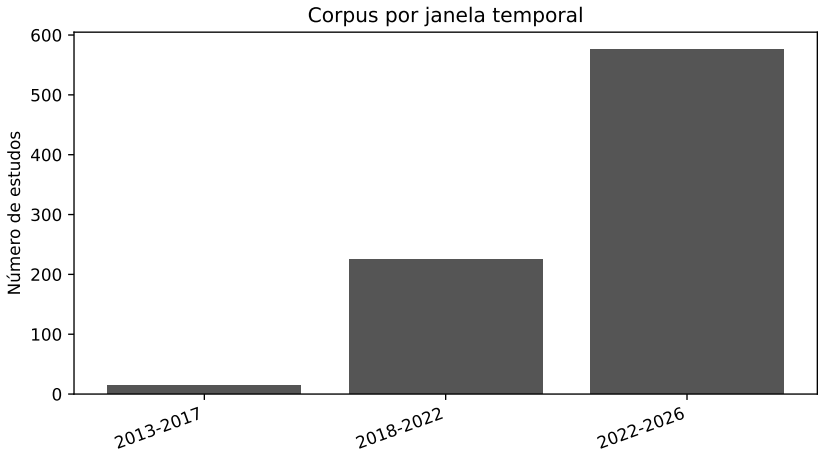


Figura 3: Corpus por janela temporal.

trata-se de um valor do campo vizinho, a unidade de análise, que o extrator empregou quando nenhuma das cinco categorias descrevia bem o desenho. Os seis trabalhos têm em comum o uso de microdados de trabalhadores ou de domicílios – registros administrativos e *surveys* longitudinais – para acompanhar trajetórias individuais, e não ocupações, setores ou firmas. São eles: o estudo de Yakymovych (2025) sobre as consequências da perda de emprego para trabalhadores de ocupações rotineiras, com dados administrativos suecos que pareiam empregadores e empregados; o de Gallen e Kim (2025), que relaciona automação e dinâmica heterogênea de rendimentos em um painel de indivíduos; os de Sun e Gao (2025) e de Nie e Xue (2026), que examinam, com pesquisas domiciliares chinesas, os efeitos da automação inteligente sobre o bem-estar subjetivo e a satisfação no trabalho e da penetração da IA sobre a qualidade do emprego; o de Wang et al. (2024), sobre IA e mobilidade ocupacional intergeracional; e o de Semtner et al. (2025), sobre habilidades socioemocionais e mobilidade no emprego. Optou-se por manter o grupo visível, em vez de redistribuí-lo, porque ele identifica um desenho que o esquema não antecipou – a evidência no nível do trabalhador, frequentemente voltada a desfechos que vão além do emprego, como renda, bem-estar e mobilidade. Por ser pequeno, o grupo é tratado, nas análises multivariadas, junto à evidência de firma, a categoria microeconômica mais próxima. A heterogeneidade de desenhos – de exercícios de exposição baseados em medidas como o índice de Felten (Felten et al., 2021) a estudos de plataformas de trabalho *online* – justifica a opção metodológica por uma síntese narrativo-estruturada, e não meta-analítica.

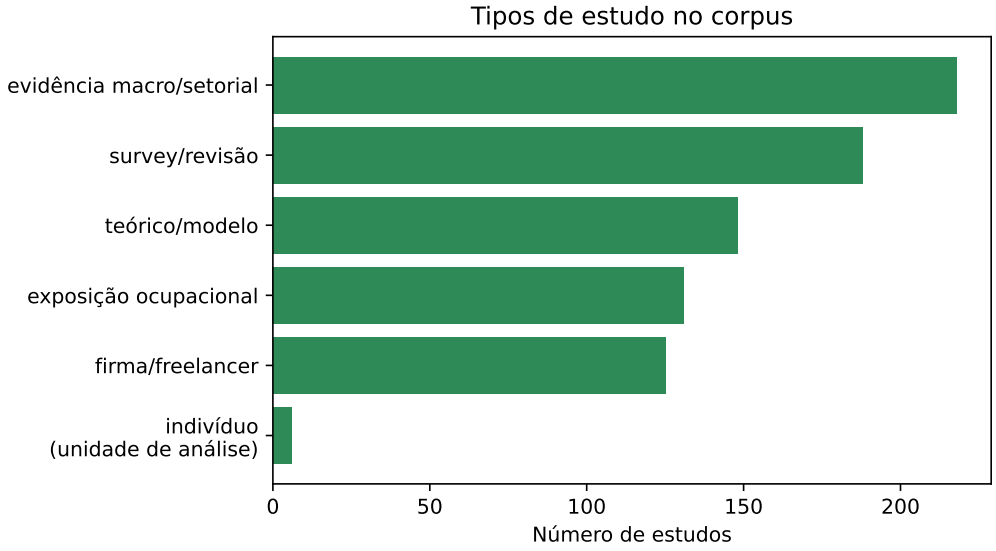


Figura 4: Tipos de estudo no corpus. A categoria "indivíduo" não integra o esquema de extração: é o valor de unidade de análise atribuído pelo extrator a seis estudos com microdados de trabalhadores.

A Figura 5 distribui o corpus pela tecnologia de IA em foco. A maior parte dos estudos trata a IA de forma genérica (319) ou foca a automação clássica (253) e a combinação de robôs e IA (160). A IA generativa e os *LLMs* aparecem explicitamente em 54 estudos, as

abordagens preditivas de *machine learning* em 27 e o *deep learning*, como foco específico, em apenas 3. Vale notar que a presença ainda modesta da rotulagem "IA generativa" não contradiz a concentração temporal recente: muitos estudos publicados após 2022 seguem analisando a automação e a IA de modo amplo, e apenas uma fração nomeia diretamente os modelos generativos como objeto. Essa constatação tem consequência analítica direta: entre os 576 estudos publicados de 2023 em diante, apenas 53 (9,2%) têm a IA generativa como objeto. "Publicado depois do ChatGPT" e "sobre a tecnologia do ChatGPT" são, portanto, coisas distintas, e a Discussão (Capítulo 7) separa as duas dimensões.

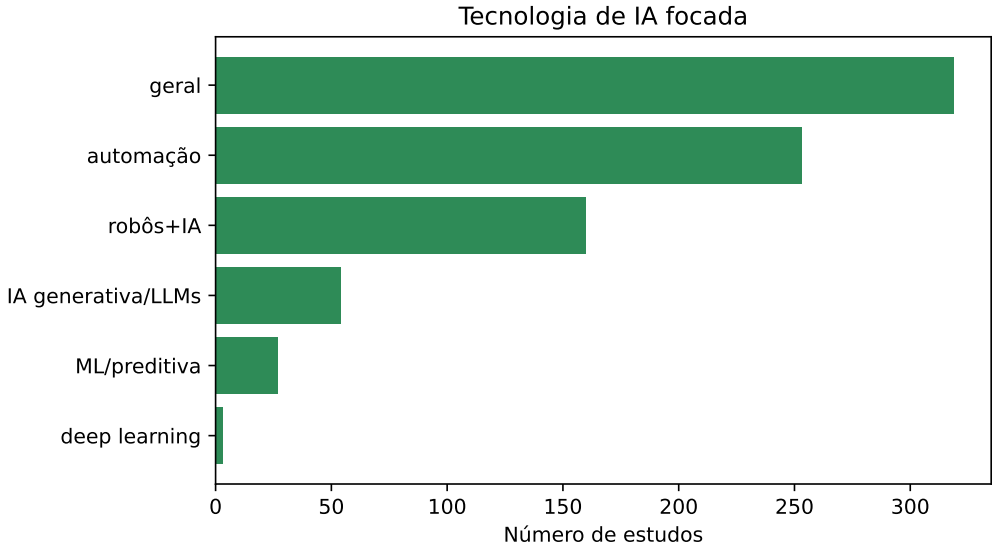


Figura 5: Distribuição do corpus por tecnologia de IA focada.

A Tabela 5 resume atributos estruturais do corpus. A maior parte são artigos de periódico (77,3%) e 86,2% são revisados por pares, o que sustenta a qualidade editorial mínima do conjunto. Quanto à estratégia empírica, predomina a análise descritiva (44,5%), seguida de regressões por mínimos quadrados ordinários (MQO) (14,8%), modelos teóricos (9,8%), modelos estruturais (9,7%) e variáveis instrumentais (9,1%); desenhos quasi-experimentais mais exigentes em identificação causal (diferenças-em-diferenças, *regression discontinuity design* (RDD), estudo de evento) somam menos de 5%. Geograficamente, quase metade dos estudos são referentes a múltiplos países (46,9%), com a China (14,2%) e os Estados Unidos à frente entre os países isolados. A presença chinesa é um fenômeno recente: os estudos com foco na China passam de 3,3% do corpus pré-ChatGPT para 18,8% do pós, de modo que a expansão da literatura é também um deslocamento geográfico de quem a produz e de onde ela olha. Nenhum *working paper* integra o corpus, pois as bases consultadas indexam periódicos e capítulos; a implicação para a cobertura é discutida na Seção **??**. Esse predomínio do descritivo sobre o identificado deve ser mantido em vista na leitura dos achados de magnitude (Seção 6) e reaparece na análise de robustez por qualidade.

Tabela 5: Atributos estruturais do corpus de análise.

Atributo	n	%
tipo_pub: journal	631	77,3%
tipo_pub: book chapter	185	22,7%
revisado_por_pares: sim	703	86,2%
revisado_por_pares: não	112	13,7%
revisado_por_pares: (não especificado)	1	0,1%
metodo_empirico: OLS	121	14,8%
metodo_empirico: IV	74	9,1%
metodo_empirico: DiD	31	3,8%
metodo_empirico: RDD	1	0,1%
metodo_empirico: evento-estudo	3	0,4%
metodo_empirico: estrutural	79	9,7%
metodo_empirico: ML	23	2,8%
metodo_empirico: experimento/survey experimental	1	0,1%
metodo_empirico: modelo teórico	80	9,8%
metodo_empirico: descritivo	363	44,5%
metodo_empirico: (não especificado)	40	4,9%
país: multipais	383	46,9%
país: China	116	14,2%
país: EUA	33	4,0%
país: India	18	2,2%
país: Alemanha	12	1,5%

Corpus de análise: N=816 estudos incluídos e extraídos. Percentuais sobre N.

5 Resultados II — Síntese por janela

Este capítulo apresenta o corpus longitudinalmente, nas três janelas tecnológicas. A Tabela 6 resume, por janela, a tecnologia e o tipo de estudo dominantes, o sinal e a polarização predominantes e a fração de estudos que mobiliza cada mecanismo teórico do arcabouço de tarefas de Acemoglu e Restrepo — deslocamento, reinstalação, complementaridade e demanda agregada.[1] A Figura 6 traça a evolução desses mecanismos.

Dois traços estão presentes nas três janelas e antecipam a discussão de continuidades do Capítulo 6: em todas elas o *sinal* predominante sobre o emprego é "ambíguo", e nas duas janelas de tamanho analisável a *polarização* modal é o risco concentrado em ocupações de baixa qualificação. A literatura econômica, vista no agregado, nunca convergiu para um veredito unívoco sobre o saldo líquido de empregos, e a tese da polarização — risco maior para tarefas rotineiras de menor qualificação — mantém-se como leitura mais frequente ao longo de todo o período. O que muda entre as janelas é o enquadramento tecnológico, o tipo de evidência e o peso relativo dos mecanismos.

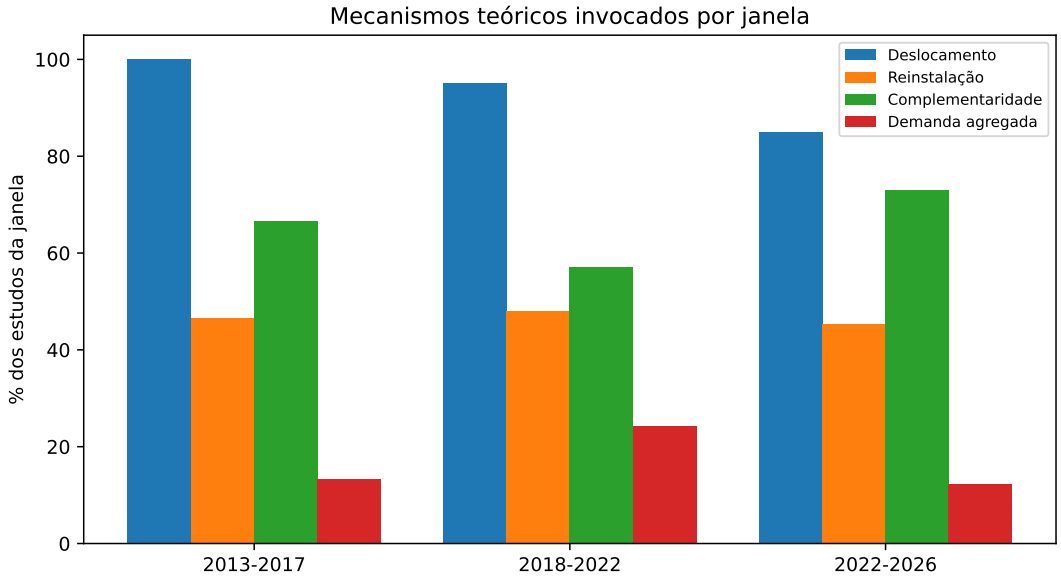


Figura 6: Mecanismos teóricos invocados por janela temporal.

A primeira janela é muito pequena (15 estudos) e serve apenas de pano de fundo: qualquer percentual calculado sobre ela muda vários pontos com a reclassificação de um único estudo. Ainda assim é nítida no enquadramento. A tecnologia dominante é a automação, e o mecanismo de *deslocamento* é onipresente – todos os estudos que classificaram a dimensão o invocam –, enquanto a *demanda agregada* aparece de forma marginal (13,3%).

O período retrata a tecnologia pela lente do efeito-substituição clássico: a máquina

[1] Os mecanismos não são mutuamente exclusivos: um mesmo estudo pode invocar mais de um, de modo que os percentuais somam mais de 100%.

Tabela 6: Síntese das dimensões por janela temporal.

Dimensão	2013-2017 (n=15)	2018-2022 (n=225)	2022-2026 (n=576)
Tecnologia dominante	automação	automação	geral
Tipo de estudo modal	teórico/modelo	teórico/modelo	evidência macro/setorial
Sinal predominante	ambíguo	ambíguo	ambíguo
Polarização predominante	ambos	baixa-quali em risco	baixa-quali em risco
Deslocamento (%)	100,0%	95,1%	85,1%
Reinstalação (%)	46,7%	47,9%	45,4%
Complementaridade (%)	66,7%	57,1%	73,0%
Demanda agregada (%)	13,3%	24,2%	12,4%

Proporções de mecanismo sobre os estudos que classificaram a dimensão (n/a fora).

desloca tarefas rotineiras, e o debate gira em torno de quanto desse deslocamento é compensado por reinstalação (46,7%) e complementaridade (66,7%). São representativos da janela a decomposição entre comércio e tecnologia nos mercados de trabalho locais de D. H. Autor et al. (2015) e a revisão crítica das estimativas de risco de automação de Arntz et al. (2017).

Na segunda janela (225 estudos) a automação segue como tecnologia dominante e o tipo modal de estudo é o teórico ou de modelagem, seguido de perto pela evidência macro/setorial: é o período em que o arcabouço de tarefas é formalizado e estendido.

O deslocamento permanece quase universal (95,1%) e a *demanda agregada* atinge seu ápice no corpus (24,2%): a difusão dos modelos preditivos convive com um debate explícito, em boa parte de equilíbrio geral, sobre os efeitos de produtividade e de expansão da demanda que poderiam recompor o emprego, como na análise do ajuste dos mercados de trabalho à robótica industrial de Dauth et al. (2021). A reinstalação (47,9%) e a complementaridade (57,1%) são invocadas por cerca de metade dos estudos. É nesta janela que a polarização com risco na *baixa* qualificação é mais hegemônica: apenas 4 dos 138 estudos que classificaram a dimensão situam o risco na alta qualificação.

A terceira janela (576 estudos) marca três inflexões. Primeiro, no tipo de evidência: a modelagem teórica perde espaço (de 29,3% para 13,2% dos estudos) e o estudo modal passa a ser a evidência macro/setorial, ao lado de um forte crescimento das revisões e dos estudos de firma.

Segundo, nos mecanismos: a *complementaridade* salta para 73,0% – o maior valor entre as janelas de tamanho analisável –, enquanto o deslocamento recua dez pontos (85,1%) e a demanda agregada cai pela metade (12,4%). A literatura da era generativa, sem abandonar a preocupação com a substituição, enfatiza de forma crescente a ampliação de capacidades e a cooperação humano-máquina, a exemplo da evidência de firma sobre IA generativa de Brynjolfsson et al. (2025); ao mesmo tempo, torna-se mais microeconômica e menos atenta aos canais de equilíbrio geral.

Terceiro, a rotulagem tecnológica torna-se mais difusa ("geral" passa a dominar), sinal de que muitos trabalhos tratam a IA de modo amplo mesmo quando o gatilho é a

onda generativa. Essas inflexões são submetidas a teste formal na comparação pareada do próximo capítulo. Convém antecipar uma cautela: a terceira janela é definida pelo calendário, e não pelo conteúdo, e menos de um décimo de seus estudos tem a IA generativa como objeto. O que a janela registra é a literatura *contemporânea* da IA generativa, em boa parte ainda dedicada à automação e à robótica; a Discussão (Capítulo 7) separa as duas coisas.

6 Resultados III — Comparação pré/pós-ChatGPT

Este capítulo compara, dimensão a dimensão, os 240 estudos publicados até 2022 com os 576 publicados de 2023 em diante, conforme a Tabela 7. O período é definido de forma determinística pelo ano de publicação (Seção **??**); como o ChatGPT foi lançado em 30 de novembro de 2022, o ano de 2023 é o primeiro ano-calendário posterior ao pivô. A hipótese de trabalho sustenta que a literatura pré-ChatGPT convergia para a polarização com risco em tarefas rotineiras de baixa qualificação, ao passo que a literatura pós-ChatGPT deslocaria o risco para tarefas cognitivas de alta qualificação. Antes de discutir os eixos, é preciso fixar a natureza dos testes: o corpus é o *censo* dos estudos incluídos, não uma amostra aleatória de uma população; os valores-p de associação (χ^2 e Fisher exato) são, por isso, lidos como medidas exploratórias de associação, e não como inferência populacional. Todas as proporções excluem do denominador os estudos que não classificaram a dimensão.

6.1 Eixo 1: Quem está em risco

O eixo que testa diretamente a hipótese da polarização (Tabela 8) procura comprar qual categoria da população estaria mais exposta ao risco. A participação de estudos que situam o risco nas ocupações de *alta* qualificação multiplica-se por cinco entre os períodos: de 2,7% (intervalo de confiança (IC) Wilson 95%: [1,1; 6,8]) no pré para 13,6% ([10,5; 17,4]) no pós, com razão de chances de 5,61 e $p < 0{,}001$ no teste exato de Fisher. Antes de 2021 não há, no corpus, um único estudo que situe o risco primordialmente na alta qualificação; em 2026 eles são quase um em cada cinco. A direção é a prevista pela hipótese, e a associação aparece também na distribuição *completa* da polarização ($\chi^2 = 13{,}58$, $p = 0{,}0035$). Ilustram esse enquadramento estudos pós-ChatGPT que situam o risco em ocupações cognitivas qualificadas, como a análise da escolha ocupacional diante da IA generativa de Goller et al. (2025) – cujo próprio título, "*This time it's different*", anuncia a tese da ruptura – e o exame das ocupações no centro da adoção de IA de Fontanelli et al. (2025).

Dois qualificadores, porém, delimitam o alcance do achado. Primeiro, a categoria modal continua sendo o risco para a *baixa* qualificação nos dois períodos (63,3% no pré, 53,7% no pós) – padrão que ecoa a literatura da automação sobre trabalhadores rotineiros

Tabela 7: Comparação pareada de dimensões pré e pós-ChatGPT.

Dimensão / categoria	Pré (n=240)	Pós (n=576)
Polarização (quem está em risco) — $\chi^2 = 13{,}58$, gl = 3, $p = 0{,}0035$ (células esperadas <5)		
baixa-quali em risco	63,3%	53,7%
alta-quali em risco	2,7%	13,6%
ambos	32,7%	31,4%
neutro	1,4%	1,3%
Sinal sobre o emprego — $\chi^2 = 27{,}93$, gl = 3, $p < 0{,}001$ (células esperadas <5)		
negativo	30,7%	21,6%
positivo	3,8%	16,8%
nulo	2,1%	2,1%
ambíguo	63,4%	59,5%
Tipo de evidência — $\chi^2 = 57{,}44$, gl = 5, $p <$ 0,001 (células esperadas <5)		
exposição ocupacional	19,2%	14,8%
evidência macro/setorial	25,4%	27,3%
firma/freelancer	4,6%	19,8%
teórico/modelo	30,0%	13,2%
survey/revisão	20,8%	24,0%
indivíduo	0,0%	1,0%
Horizonte — $\chi^2 = 66{,}07$, gl = 3, $p < 0{,}001$		
curto prazo	2,9%	10,5%
médio prazo	40,3%	61,8%
longo prazo	46,6%	24,0%
projeção	10,1%	3,7%
Mecanismos teóricos (% que invoca)		
Deslocamento ($p < 0{,}001$)	95,4%	85,1%
Reinstalação ($p = 0{,}5344$)	47,9%	45,4%
Complementaridade ($p < 0{,}001$)	57,8%	73,0%
Demanda agregada ($p < 0{,}001$)	23,5%	12,4%

Proporções calculadas sobre os estudos que classificaram cada dimensão (n/a fora do denominador); o denominador varia por linha.

e desigualdade, a exemplo de Moll et al. (2022) –, e a categoria "ambos"mantém peso elevado e estável (32,7% e 31,4%). O crescimento do risco atribuído à alta qualificação se faz, portanto, à custa da hegemonia da baixa qualificação, mas sem revogá-la.

Segundo, quando se restringe a análise aos estudos de maior qualidade metodológica (*score* ≥ 4, Tabela 9), a elevação persiste em direção (5,9% para 12,5%), mas não se distingue do acaso ($p = 0{,}5128$), com apenas 34 estudos classificados no pré. A Tabela 14, discutida no Capítulo 7, mostra que o resultado resiste a oito outras especificações e que a perda de significância nesse subconjunto decorre mais do tamanho da amostra do que de uma reversão do efeito. O mesmo capítulo mostra que a mudança se concentra nos estudos cujo objeto é a IA: entre os que tratam de robótica e automação, a fração que aponta a alta qualificação é de 1,8% no pré e de 3,1% no pós (Tabela 15). A leitura é de *ruptura parcial*: o enquadramento do risco para tarefas cognitivas de alta qualificação cresce de forma nítida e robusta após o ChatGPT, mas permanece minoritário e não desloca o diagnóstico de polarização herdado.

Tabela 8: Foco da hipótese: risco para alta qualificação, pré vs. pós-ChatGPT.

Polarização	Pré (n=147)	Pós (n=376)
alta-quali em risco	2,7% [1,1; 6,8]	13,6% [10,5; 17,4]
Demais categorias	97,3%	86,4%

Fisher exato: razão de chances (pós/pré) = 5,61, $p < 0{,}001$; IC Wilson 95% entre colchetes.

Tabela 9: Robustez: polarização restrita a estudos de alta qualidade (score ≥ 4).

Polarização (score$\geq$4)	Pré (n=34)	Pós (n=88)
Alta-quali em risco	5,9%	12,5%
Demais categorias	94,1%	87,5%

Subconjunto de robustez: estudos com score de qualidade ≥ 4. n é o número com polarização classificada nesse subconjunto (n/a fora). Fisher exato: $p = 0{,}5128$. Células pequenas; leitura cautelosa.

6.2 Eixo 2: Qual o mecanismo

Três dos quatro mecanismos do arcabouço de Acemoglu e Restrepo mudam de peso relativo entre os períodos. A *complementaridade* sobe de 57,8% para 73,0% dos estudos ($p < 0{,}001$). O *deslocamento* permanece o mecanismo mais invocado em ambos os períodos, mas deixa de ser quase universal: recua de 95,4% para 85,1% ($p < 0{,}001$). A *demanda agregada* cai praticamente pela metade, de 23,5% para 12,4% ($p < 0{,}001$). Apenas a *reinstalação* permanece estável (47,9% e 45,4%, $p = 0{,}5344$). A literatura pós-ChatGPT não abandona a tese da substituição, mas passa a enfatizar com mais frequência a complementaridade entre humanos e IA, ao mesmo tempo em que fala menos dos efeitos de equilíbrio geral. São exemplos da primeira linha, no corpus, a evidência

sobre a origem e o conteúdo de novas ocupações ao longo de quase oito décadas (D. Autor et al., 2024) e os ganhos de produtividade da IA generativa concentrados nos trabalhadores menos experientes (Brynjolfsson et al., 2025). O fato de a reinstalação não acompanhar a complementaridade merece registro e é retomado na Discussão: a literatura recente documenta que a IA *ajuda* o trabalhador nas tarefas existentes com muito mais frequência do que documenta a criação de tarefas *novas*.

6.3 Eixo 3: Como se mede

A forma de medir o efeito também se transforma. O tipo de evidência muda de maneira marcada ($\chi^2 = 57{,}44$, $p < 0{,}001$, Tabela 7). A mudança mais expressiva é o recuo da modelagem teórica (30,0% para 13,2%) e a multiplicação por quatro dos estudos de firma e de plataformas de *freelancers* (4,6% para 19,8%; p. ex. (J. Bessen et al., 2025; Hémous et al., 2025)). Os estudos de exposição ocupacional recuam (19,2% para 14,8%; típicos do período anterior, p. ex. (Lordan & Neumark, 2018)), enquanto a evidência macro/setorial (25,4% e 27,3%) e as revisões (20,8% e 24,0%) mantêm-se aproximadamente estáveis. O campo se desloca, assim, do modelo para o dado e do agregado para a firma.

A magnitude dos efeitos, contudo, permanece pouco comparável (Tabela 10). Apenas 12,1% dos estudos do pré e 13,5% do pós reportam um efeito normalizável; entre esses, a mediana da magnitude normalizada passa de 0,453 para 0,093, mas as faixas são amplas e a unidades, heterogêneas, de modo que a diferença não comporta interpretação substantiva. Coerentemente com o desenho narrativo-estruturado e não meta-analítico, não se agregam (*pooling*) essas magnitudes nem se aplica teste de hipótese sobre elas; o sinal qualitativo permanece o eixo principal de síntese. Essa baixa cobertura, somada ao predomínio de desenhos descritivos documentado no Capítulo 4, é uma limitação substantiva do estado atual da literatura, não apenas desta revisão.

Tabela 10: Cobertura e descritivo da magnitude normalizada, pré vs. pós-ChatGPT.

Magnitude normalizada	Pré	Pós
Cobertura (normalizável)	29/240 (12,1%)	78/576 (13,5%)
Mediana	0,453	0,093
Q1–Q3	[0,050; 0,630]	[-0,011; 0,488]
Faixa (mín–máx)	[-9,000; 35,800]	[-12,970; 16,300]

Sem teste de hipótese: cobertura baixa, unidades heterogêneas, não-pooling (revisão narrativa-estruturada, não meta-analítica).

6.4 Eixo 4: O que se sabe vs. o que se projeta

O horizonte dos achados se encurta de forma acentuada após o ChatGPT ($\chi^2 = 66{,}07$, $p < 0{,}001$): os estudos de curto prazo mais que triplicam de participação (2,9% para

10,5%), o médio prazo torna-se majoritário (40,3% para 61,8%), o longo prazo cai quase pela metade (46,6% para 24,0%) e as projeções recuam de 10,1% para 3,7%. A literatura recente é, nesse sentido, menos especulativa e mais ancorada em efeitos observáveis no presente, como nas primeiras estimativas dos efeitos da IA generativa sobre o emprego a partir de dados populacionais (Kauhanen & Rouvinen, 2025).

O sinal sobre o emprego também muda ($\chi^2 = 27{,}93$, $p < 0{,}001$), e a mudança não é a que o debate público sugeriria: o sinal "negativo" recua (30,7% para 21,6%) e o "positivo" mais que quadruplica (3,8% para 16,8%), enquanto o "ambíguo" segue majoritário e praticamente estável (63,4% e 59,5%). Em vez de um veredito mais alarmista, a evidência pós-ChatGPT é, no agregado, *menos pessimista* quanto ao saldo de empregos. O Capítulo 7 mostra que parte dessa mudança decorre de *o que* a literatura recente mede, e não apenas do que ela encontra, e que tanto o encurtamento do horizonte quanto o sinal mais positivo aparecem também na literatura de robótica – são, portanto, traços do amadurecimento empírico do campo, e não efeitos da IA generativa.

6.5 Continuidades

Três elementos constituem o núcleo de continuidade entre os dois períodos: (i) o sinal predominante sobre o emprego é ambíguo antes e depois; (ii) a categoria modal de polarização continua sendo o risco para a baixa qualificação; e (iii) o deslocamento permanece o mecanismo mais mobilizado, e a reinstalação é invocada por pouco menos da metade dos estudos nos dois períodos. A tese da polarização e a centralidade do efeito-substituição, herdadas da era da automação, sobrevivem à chegada da IA generativa como moldura dominante.

6.6 Rupturas

As rupturas são mais numerosas e mais fortes do que as continuidades, e todas resistem à correção de Holm para comparações múltiplas (Tabela 20): quintuplica a fração de estudos que situam o risco na alta qualificação; cresce a complementaridade e recuam o deslocamento e a demanda agregada como mecanismos; o tipo de evidência migra da modelagem teórica para os estudos de firma e de plataformas; o horizonte se encurta; e o sinal torna-se menos negativo e mais frequentemente positivo. O retrato que emerge não é o de uma inversão do consenso anterior – a baixa qualificação segue modal, o sinal segue ambíguo –, mas tampouco o de mera mudança de ênfase: é o de um *deslocamento parcial e consistente de diagnóstico*. A IA generativa traz o trabalho cognitivo qualificado para dentro da zona de risco e desloca a discussão da substituição para a complementaridade, sem revogar o diagnóstico de polarização que a literatura vinha construindo desde a era da automação.

Uma comparação entre períodos não permite, porém, atribuir essas rupturas à IA

generativa: tudo o que mudou no campo entre 2022 e 2023 está nelas confundido. O Capítulo 7 enfrenta essa limitação usando a literatura de robótica e automação como grupo de comparação, e o resultado reordena a lista acima. O deslocamento do risco para a alta qualificação e, em parte, a alta da complementaridade são *específicos do objeto*: não ocorrem entre os estudos de robótica. O encurtamento do horizonte, o recuo da demanda agregada e o sinal mais positivo são *de época*: ocorrem com intensidade semelhante nas duas literaturas.

7 Discussão — o que mudou, por que mudou e quanto se pode confiar

Os capítulos anteriores descrevem *o que* mudou na literatura entre os dois períodos. Este capítulo pergunta *por que* mudou e confronta os achados com o referencial teórico do Capítulo 2. Ele se organiza em torno de cinco perguntas que a comparação bruta pré/pós deixa em aberto: se o deslocamento do risco acompanha a *data* ou o *objeto* tecnológico dos estudos; quais das mudanças observadas resistem ao confronto com um grupo de comparação, formado pelos estudos de robótica e automação; se o sinal sobre o emprego depende do que cada desenho mede; quanto das mudanças é recomposição do corpus e quanto é mudança dentro de cada tipo de estudo; e quão sensíveis são as conclusões às escolhas metodológicas da revisão. As análises são, como no restante do trabalho, exploratórias.

7.1 Data ou objeto? O risco acompanha a tecnologia estudada

A comparação pré/pós agrupa os estudos pela data de publicação, mas a hipótese da revisão é, no fundo, uma hipótese sobre *tecnologia*: a de que a IA generativa atinge tarefas distintas das que a automação atingia. As duas coisas não coincidem, pois apenas 9,2% dos estudos publicados de 2023 em diante têm a IA generativa como objeto (Capítulo 4). A Tabela 11 separa as duas dimensões, e o resultado é o mais nítido de toda a revisão. Entre os estudos cujo objeto é a automação clássica ou a robótica, o risco para a alta qualificação é praticamente ausente (2,1% e 3,4%) e a baixa qualificação é o diagnóstico de dois terços dos trabalhos. Entre os estudos cujo objeto é a IA generativa, a ordem se inverte: o risco para a alta qualificação é a categoria *modal* (48,5%), e a baixa qualificação cai a 27,3%. Os estudos que tratam a IA de modo geral ocupam posição intermediária (17,0%).

A leitura teórica que fazemos é favorável ao arcabouço de tarefas. O modelo de D. H. Autor et al. (2003) nunca afirmou que a tecnologia ameaça a baixa qualificação; afirmou que ela substitui as tarefas que consegue executar, e que essas tarefas eram, para o computador,

Tabela 11: Polarização segundo a tecnologia em foco no estudo.

Tecnologia em foco	n	Baixa-quali	Alta-quali	Ambos	Neutro
automação	190	66,8%	2,1%	29,5%	1,6%
ML/preditiva	12	58,3%	16,7%	25,0%	0,0%
IA generativa/LLMs	33	27,3%	48,5%	24,2%	0,0%
robôs+IA	116	69,8%	3,4%	24,1%	2,6%
geral	171	40,9%	17,0%	41,5%	0,6%

Percentuais na linha, sobre os estudos que classificaram a polarização (categorias com $n < 5$ omitidas). IA generativa vs. demais, alta-quali em risco: RC = 10,88, Fisher $p < 0{,}001$.

as rotineiras, concentradas nas ocupações de qualificação *média*; a literatura de robótica estendeu o raciocínio às tarefas manuais rotineiras (Acemoglu & Restrepo, 2020a).

Cabe, contudo, uma precisão: o esquema de extração desta revisão não distingue a qualificação média da baixa, de modo que a categoria "baixa-quali em risco" absorve o esvaziamento do meio da distribuição descrito por D. H. Autor e Dorn (2013), e o contraste que a tabela registra é entre essa categoria ampla e a alta qualificação. O que os índices de exposição da geração seguinte mostraram é que o conjunto de tarefas executáveis pela IA é outro (Eloundou et al., 2024; Felten et al., 2021; Webb, 2020). O corpus reproduz exatamente essa estrutura: a literatura não mudou de ideia sobre a automação — nos estudos sobre automação e robôs, a baixa qualificação é o diagnóstico de 68,8% dos trabalhos no pré e de 67,5% no pós, e a alta qualificação, de 1,8% e 3,1% —, mas passou a estudar também uma tecnologia cujo perfil de tarefas é diferente, e para ela o diagnóstico é diferente.

A ruptura está no *objeto*; a continuidade está na *teoria*. Nesse sentido, a hipótese de trabalho da revisão é confirmada onde ela de fato se aplica, e a expressão "ruptura parcial" ganha conteúdo preciso: a ruptura é parcial porque a IA generativa ainda é o objeto de uma parcela pequena da literatura indexada, e não porque o diagnóstico sobre ela seja minoritário. Esse diagnóstico é majoritário sem ser consolidado: apoia-se em 33 estudos, o intervalo de confiança de Wilson para os 48,5% vai de 32,5% a 64,8%, e os 16 trabalhos que o sustentam são índices de exposição, revisões e modelos teóricos, metade deles com sinal ambíguo sobre o emprego. A IA generativa muda a resposta à pergunta "quem?" na literatura que a toma por objeto; a evidência de firma ou agregada que permitiria dizer "quanto?" ainda não existe nesse grupo.

O objeto explica, porém, apenas parte do efeito de período, e a parte restante precisa ser examinada antes de ser interpretada. A Tabela 12 mostra que, controlando-se pelo objeto (IA generativa/LLMs), publicar de 2023 em diante ainda eleva as chances de situar o risco na alta qualificação (razão de chances de 4,06 na coluna 2 e de 3,18 com todos os controles), e a Tabela 14 mostra que o efeito sobrevive à *exclusão* de todos os estudos de IA generativa (2,7% para 10,2%). Como todos os 33 estudos de IA generativa com

Tabela 12: Determinantes de o estudo situar o risco na alta qualificação (logit).

	(1)	(2)	(3)
Publicado em 2023+	5,61* [1,99; 15,82]	4,06* [1,42; 11,65]	3,18* [1,07; 9,44]
Objeto: IA generativa/LLMs	—	8,28* [3,85; 17,83]	12,87* [5,15; 32,16]
Tipo: exposição ocupacional	—	—	1,83 [0,70; 4,77]
Tipo: firma/*freelancer*	—	—	2,98* [1,21; 7,37]
Tipo: *survey*/revisão	—	—	0,69 [0,22; 2,12]
Tipo: teórico/modelo	—	—	0,67 [0,19; 2,40]
País-foco: China	—	—	1,13 [0,51; 2,51]
Score ≥ 4	—	—	1,05 [0,50; 2,18]
Texto completo	—	—	0,81 [0,34; 1,92]
n	523	523	523
Pseudo-R^2 (McFadden)	0,047	0,123	0,165

Logit; variável dependente: o estudo situa o risco na alta qualificação. Razões de chances com IC 95% entre colchetes; * $p < 0{,}05$. Categoria de referência do tipo: evidência macro/setorial.

polarização classificada são posteriores a 2022, o coeficiente do objeto é um contraste interno ao período pós, e o do período é identificado pelos demais estudos. O canal é visível nos estudos de IA "geral", nos quais a fração que aponta a alta qualificação passa de 1 em 32 no pré para 28 em 139 no pós. A leitura imediata seria a de uma *difusão do enquadramento*: a chegada da IA generativa teria alterado a forma como a literatura fala de IA em sentido amplo, mesmo quando o estudo não trata de modelos generativos.

A Tabela 13 mostra que essa leitura não se sustenta. Dos 55 estudos codificados como "alta-quali em risco", 20 atribuem à tecnologia sinal *positivo* sobre o emprego; entre os 35 publicados de 2023 em diante que não tratam de IA generativa, são 18, em sua maioria evidência de firma sobre *skill upgrading* (a razão de chances de 2,98 do tipo firma/*freelancer* na coluna 3 do logit é a marca desse grupo). O extrator usou a categoria para registrar *qual* grupo a tecnologia atinge, e não apenas qual grupo perde. Quando se exige sinal não positivo (Tabela 14, definição estrita), o efeito de período permanece no corpus inteiro (2,0% para 8,5%, $p = 0{,}006$), mas desaparece fora da IA generativa (2,0% para 5,0%, $p = 0{,}21$), ao passo que o contraste entre a IA generativa e os demais objetos se mantém (15 em 33 contra 20 em 490, $p < 0{,}001$). O que cresceu fora da IA generativa não foi, portanto, a percepção de risco para a alta qualificação, e sim a evidência de que a IA não generativa *complementa* a alta qualificação, que no arcabouço de Acemoglu e Restrepo (2019) é efeito de produtividade e de complementaridade, não de deslocamento. A separação entre objeto e data sai mais nítida do que a primeira leitura sugeria: a literatura sobre IA não generativa descreve uma tecnologia complementar à alta qualificação; a literatura sobre IA generativa, uma tecnologia que a ameaça.

A Figura 7 acrescenta a dimensão anual. A fração cresce de 2021 a 2026, e um logit sobre o ano de publicação estima uma razão de chances de 1,46 por ano ($p < 0{,}001$; 1,38 sem os estudos de IA generativa, $p = 0{,}002$). Os dados, contudo, não permitem

Tabela 13: Polarização e sinal do efeito sobre o emprego.

Polarização	n	Negativo	Positivo	Nulo	Ambíguo
baixa-quali em risco	295	116	37	2	140
alta-quali em risco	55	12	20	1	22
ambos	166	25	8	1	132
neutro	7	0	2	5	0
Alta-quali em risco, por subgrupo					
objeto IA generativa/LLMs	16	7	1	0	8
demais objetos, publicados em 2023+	35	5	18	1	11
demais objetos, publicados até 2022	4	0	1	0	3

Contagens sobre os estudos que classificaram polarização e sinal. Um estudo codificado como "alta-quali em risco" com sinal positivo situa a alta qualificação como o grupo *atingido* pela tecnologia, não como o grupo que perde: tipicamente evidência de firma sobre *skill upgrading*.

distinguir um degrau em 2023 de uma tendência iniciada antes dele: o período pré conta com apenas quatro estudos que apontam a alta qualificação (um em 2021 e três em 2022), a tendência estimada dentro de cada período isoladamente não é significativa, e, num logit que inclui o ano e o indicador de período, o indicador perde toda a significância ($p = 0{,}76$) enquanto o ano a conserva ($p = 0{,}03$). A compatibilidade com uma tendência anterior ao ChatGPT está em linha com o fato de que os índices de exposição à IA preditiva já apontavam para a alta qualificação antes dele (Felten et al., 2021; Webb, 2020); afirmar que o lançamento *acelerou* essa tendência, porém, iria além do que os dados aqui apresentados podem sustentar.

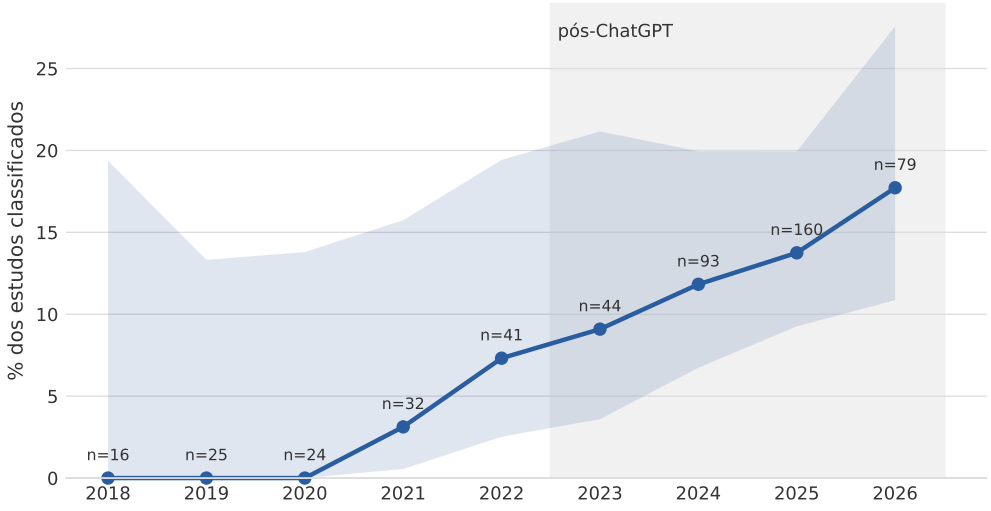


Figura 7: Fração dos estudos que situam o risco na alta qualificação, por ano de publicação (faixa: IC Wilson 95%; n = estudos que classificaram a polarização).

A Tabela 14 documenta também a fragilidade que esta revisão corrigiu. Na primeira versão da análise, a posição pré/pós era atribuída pelo modelo de linguagem extrator, que, sem instrução explícita, classificou como "pré" 115 estudos publicados entre 2023 e 2026

Tabela 14: Sensibilidade do teste da hipótese central a definições e subconjuntos.

Especificação	Pré	Pós	RC	Fisher
Principal: ano de publicação (pós = 2023+)	4/147 (2,7%)	51/376 (13,6%)	5,61	$p < 0{,}001$
Classificação original do LLM	17/228 (7,5%)	38/295 (12,9%)	1,84	$p = 0{,}0609$
Pivô alternativo: pós = 2024+ (defasagem editorial)	8/191 (4,2%)	47/332 (14,2%)	3,77	$p < 0{,}001$
Excluindo a transição 2022–2023	1/106 (0,9%)	47/332 (14,2%)	17,32	$p < 0{,}001$
Apenas revisados por pares	4/130 (3,1%)	47/338 (13,9%)	5,09	$p < 0{,}001$
Apenas estudos empíricos	3/81 (3,7%)	37/250 (14,8%)	4,52	$p = 0{,}0058$
Excluindo estudos sobre a China	3/140 (2,1%)	38/290 (13,1%)	6,89	$p < 0{,}001$
Excluindo estudos de IA generativa/LLMs	4/147 (2,7%)	35/343 (10,2%)	4,06	$p = 0{,}0035$
Definição estrita: alta-quali e sinal não positivo	3/147 (2,0%)	32/376 (8,5%)	4,47	$p = 0{,}0059$
Definição estrita, excluindo IA generativa/LLMs	3/147 (2,0%)	17/343 (5,0%)	2,50	$p = 0{,}2109$
Apenas *score* de qualidade ≥ 4	2/34 (5,9%)	11/88 (12,5%)	2,29	$p = 0{,}5128$
Apenas lidos em texto completo	1/27 (3,7%)	7/74 (9,5%)	2,72	$p = 0{,}6783$

Fração de estudos que situam o risco na alta qualificação, entre os que classificaram a polarização. RC = razão de chances (pós/pré).

cujos *dados* eram anteriores a 2022. Com aquela variável o efeito era fraco (7,5% para 12,9%, $p = 0{,}0609$); com o ano de publicação, que é o critério declarado na metodologia, ele é forte. O resultado é insensível à escolha do pivô (2023 ou 2024), à exclusão dos anos de transição, à restrição a estudos revisados por pares ou empíricos e à exclusão dos estudos sobre a China. Perde significância na definição estrita sem os estudos de IA generativa, pela razão discutida acima, e nos dois menores subconjuntos — estudos de *score* ≥ 4 e estudos lidos em texto completo —, nos quais a direção se mantém, mas o grupo pré tem 34 e 27 estudos classificados, respectivamente.

7.2 A robótica como grupo de comparação

Se o deslocamento do risco decorre do objeto tecnológico, e não de uma mudança geral de entendimento do campo, ele *não* deve aparecer nos estudos cujo objeto não mudou. Os 413 estudos sobre robótica e automação clássica oferecem esse teste: cobrem os dois períodos (160 publicados até 2022 e 253 de 2023 em diante; os totais coincidem, por acaso, com os das duas categorias no Capítulo 4), nenhum dos trabalhos publicados de 2023 em diante menciona modelos generativos no título, e tratam de uma tecnologia cujo perfil de tarefas é o mesmo antes e depois do ChatGPT. A Tabela 15 repete, dentro desse grupo, a comparação pré/pós do Capítulo 6; as colunas da direita fazem o mesmo para os estudos que tratam a IA de modo geral, que não são um placebo, mas um grupo de contraste cujo rótulo tampouco mudou.

Tabela 15: Teste placebo: comparação pré/pós dentro de cada objeto tecnológico.

	Robótica e automação			IA em geral		
Desfecho	Pré	Pós	Fisher	Pré	Pós	Fisher
Risco na alta qualificação	1,8%	3,1%	$p = 0{,}7150$	3,1%	20,1%	$p = 0{,}0184$
Risco na alta qualificação (definição estrita)	0,9%	2,6%	$p = 0{,}4207$	3,1%	8,6%	$p = 0{,}4662$
Sinal negativo	37,1%	28,6%	$p = 0{,}0821$	18,6%	14,6%	$p = 0{,}4541$
Sinal positivo	3,8%	13,5%	$p < 0{,}001$	4,3%	21,5%	$p < 0{,}001$
Invoca deslocamento	96,2%	90,9%	$p = 0{,}0472$	94,4%	79,8%	$p = 0{,}0036$
Invoca complementaridade	51,9%	61,1%	$p = 0{,}0797$	68,7%	83,9%	$p = 0{,}0084$
Invoca demanda agregada	23,6%	13,0%	$p = 0{,}0067$	26,1%	14,7%	$p = 0{,}0312$
Horizonte de longo prazo/projeção	57,2%	27,8%	$p < 0{,}001$	54,3%	25,5%	$p < 0{,}001$

Colunas 2–4: estudos cujo objeto é robótica ou automação (placebo). Colunas 5–7: estudos que tratam a IA de modo geral. Definição estrita: alta qualificação em risco e sinal não positivo. Os estudos de IA generativa não comportam o teste, pois só um é anterior a 2023.

O teste separa dois tipos de mudança, embora com menos nitidez do que a leitura das proporções sugere. A primeira é *específica do objeto*. Na robótica não há evidência de que a fração de estudos que situam o risco na alta qualificação se mova (1,8% e 3,1%, $p = 0{,}7150$), mas o teste tem pouco poder: com dois e seis eventos, a razão de chances de 1,76 tem intervalo de confiança de 0,35 a 8,85. Apenas uma multiplicação por cinco ou mais seria detectada com probabilidade razoável. Nos estudos de IA em geral a fração passa de 3,1% para 20,1%, mas a diferença entre os dois grupos não é estatisticamente estabelecida (interação período × grupo, $p = 0{,}26$). A definição estrita da seção anterior resolve a ambiguidade de outro modo: exigido o sinal não positivo, a IA em geral também não se move (3,1% para 8,6%, $p = 0{,}4662$), e a robótica fica em 0,9% para 2,6%. Nenhum dos dois grupos cujo objeto permaneceu o mesmo desloca o risco para a alta qualificação; o deslocamento está inteiramente nos estudos de IA generativa, que não comportam o teste porque só um deles é anterior a 2023. É nesse sentido, e com essa ressalva de poder estatístico, que o placebo é encontrado na variável da hipótese central: o deslocamento do risco não é um traço da época, e sim da tecnologia de que se fala.

A segunda é *de época* e atinge o campo inteiro. O encurtamento do horizonte (de 57,2% para 27,8% de estudos de longo prazo ou projeção), o recuo da demanda agregada (23,6% para 13,0%) e o crescimento do sinal positivo (3,8% para 13,5%) ocorrem dentro da literatura de robótica com intensidade indistinguível da observada na de IA em geral (interações com p entre 0,57 e 0,99). A complementaridade pertence a este grupo, e não ao primeiro: cresce cerca de dez pontos nas duas literaturas, e a diferença entre elas não é significativa ($p = 0{,}19$). Essas mudanças não são, portanto, específicas do objeto generativo.

Duas explicações são compatíveis com o padrão, e o desenho não as distingue. A primeira é o amadurecimento empírico do campo: a disponibilidade de dados de firma e de adoção permitiu substituir projeções e modelos por estimativas de médio prazo. A Tabela 18 mostra, porém, que o encurtamento do horizonte e a alta do sinal positivo sobrevivem ao controle pelo tipo de evidência, de modo que não se trata apenas de recomposição dos desenhos: dentro de cada tipo, os horizontes encurtaram. A segunda é um efeito de época da própria onda generativa sobre o campo inteiro, que teria atraído estudos de curto prazo e de adoção sobre qualquer IA. A leitura do Capítulo 6 deve, em qualquer dos casos, ser qualificada: das rupturas ali listadas, apenas o deslocamento do risco está associado ao objeto IA generativa; as demais são movimentos de toda a literatura que coincidem no tempo com ela.

Tabela 16: Literatura de robótica vs. literatura de IA generativa (publicados de 2023 em diante).

Característica	Robôs+IA ($n = 115$)	IA generativa ($n = 53$)	Fisher
Risco na alta qualificação	4,5% (4/89)	48,5% (16/33)	$p < 0{,}001$
Risco na baixa qualificação	67,4% (60/89)	27,3% (9/33)	$p < 0{,}001$
Sinal negativo	24,6% (28/114)	20,8% (11/53)	$p = 0{,}6957$
Sinal positivo	19,3% (22/114)	9,4% (5/53)	$p = 0{,}1199$
Invoca deslocamento	91,3% (105/115)	90,6% (48/53)	$p = 1{,}0000$
Invoca reinstalação	44,1% (49/111)	30,8% (16/52)	$p = 0{,}1236$
Invoca complementaridade	69,3% (79/114)	84,9% (45/53)	$p = 0{,}0368$
Invoca demanda agregada	11,0% (12/109)	1,9% (1/52)	$p = 0{,}0626$
Horizonte de curto prazo	2,6% (3/114)	28,3% (15/53)	$p < 0{,}001$
Tipo: *survey*/revisão	14,8% (17/115)	45,3% (24/53)	$p < 0{,}001$
Tipo: evidência macro/setorial	42,6% (49/115)	9,4% (5/53)	$p < 0{,}001$
Método com identificação causal	35,7% (40/112)	12,0% (6/50)	$p = 0{,}0023$
Score de qualidade ≥ 4	40,0% (46/115)	11,3% (6/53)	$p < 0{,}001$
Entre os empíricos: identificação causal	47,6% (40/84)	23,8% (5/21)	$p = 0{,}0535$
Entre os empíricos: *score* ≥ 4	40,5% (34/84)	23,8% (5/21)	$p = 0{,}2092$

Apenas estudos publicados de 2023 em diante. Proporções sobre os estudos que classificaram cada dimensão, com numerador e denominador entre parênteses. Identificação causal: IV, DiD, RDD ou estudo de evento. 'Empíricos': exposição ocupacional, evidência macro/setorial, firma/*freelancer* e indivíduo.

A Tabela 16 confronta diretamente as duas literaturas, restringindo ambas aos estudos publicados de 2023 em diante para igualar o calendário. O grupo de comparação é aqui apenas o dos estudos sobre robôs e IA, o análogo tecnológico mais próximo; incluir a automação clássica não altera nenhum dos resultados (entre seus 105 estudos publicados de 2023 em diante, 1,9% apontam a alta qualificação e 67,6%, a baixa). Três resultados se destacam. Primeiro, a diferença de diagnóstico sobre *quem* está em risco é acentuada (V de Cramér de 0,55 sobre a distribuição completa; é, note-se, uma comparação entre os dois extremos do corpus, e as associações de cada dimensão com o período, medidas sobre o corpus inteiro, não passam de 0,29): 67,4% dos estudos de robótica apontam a baixa qualificação e 48,5% dos de IA generativa apontam a alta. Segundo, as duas

literaturas *não* diferem quanto ao sinal sobre o emprego nem quanto à centralidade do deslocamento, invocado por nove em cada dez estudos de ambas: a IA generativa muda a resposta à pergunta "quem?", não à pergunta "quanto?". Terceiro, e mais importante para a interpretação, as duas literaturas têm maturidade empírica muito desigual, em boa parte porque são feitas de desenhos diferentes. A de robótica é dominada por evidência macro/setorial, mais de um terço de seus estudos usa método com identificação causal e 40,0% alcançam *score* de qualidade igual ou superior a 4. A de IA generativa é composta quase pela metade de revisões, tem 12,0% de estudos com identificação causal e 11,3% de *score* elevado, e praticamente ignora os efeitos de demanda agregada (um estudo em 52). Restringida a comparação aos estudos empíricos, a distância encolhe e deixa de ser significativa (47,6% contra 23,8% com identificação causal, $p = 0{,}0535$; 40,5% contra 23,8% com *score* elevado, $p = 0{,}2092$), com apenas 21 estudos empíricos de IA generativa: a desigualdade de maturidade é, antes de tudo, uma desigualdade na composição dos desenhos. Dos treze contrastes da tabela, sete resistem à correção de Holm; complementaridade e demanda agregada não.

Essa desigualdade impõe uma qualificação decisiva ao achado central. Os 16 estudos de IA generativa que situam o risco na alta qualificação são seis exercícios de exposição ocupacional, seis revisões e quatro modelos teóricos; nenhum é evidência de firma ou macro/setorial. O diagnóstico de risco para o trabalho cognitivo qualificado é, no estado atual do corpus, um diagnóstico de *exposição* e de *expectativa*, não de efeitos realizados. A literatura de robótica percorreu esse mesmo caminho: começou com os índices de suscetibilidade de Frey e Osborne (2017), que previam perdas amplas, e só anos depois produziu as estimativas causais de Acemoglu e Restrepo (2020a), Graetz e Michaels (2018) e Dauth et al. (2021): efeitos negativos, mas concentrados nas regiões e ocupações expostas, no primeiro caso, e em parte compensados pela realocação para outros setores, nos dois últimos. É razoável esperar que a literatura de IA generativa siga trajetória semelhante, e a comparação sugere cautela simétrica: nem a ausência atual de efeitos agregados nem a exposição elevada das ocupações qualificadas são, ainda, evidência sobre o saldo de longo prazo.

7.3 O sinal depende do que se mede

A Introdução conjecturou que os diagnósticos da literatura divergem "menos por erro do que por medirem objetos distintos". Embora o protocolo de codificação não identifique diretamente o desfecho mensurado por um estudo, ele mapeia o tipo de evidência – variável que, em grande medida, determina o resultado: um índice de exposição afere a suscetibilidade técnica; um estudo de firma analisa a produtividade e o emprego da empresa adotante; e um modelo teórico deriva saldos condicionais a parâmetros. A Tabela 17 cruza o tipo de evidência com o sinal apurado sobre o emprego, confirmando a hipótese

inicial. A associação entre as variáveis (V de Cramér de 0,30)[2] revela-se mais forte do que a observada em qualquer dimensão temporal e mantém-se estável ao longo do tempo — com V de 0,28 para os estudos anteriores a 2023 e de 0,30 para os posteriores. Sob essa ótica, metade das pesquisas baseadas em exposição ocupacional aponta para efeitos negativos; mais de 40% dos trabalhos em nível de firma identificam impactos positivos; e cerca de 80% dos modelos teóricos e revisões registram um efeito ambíguo.

Tabela 17: Sinal sobre o emprego segundo o tipo de evidência.

Tipo de evidência	n	Negativo	Positivo	Nulo	Ambíguo
exposição ocupacional	129	49,6%	7,8%	0,8%	41,9%
evidência macro/setorial	217	25,3%	15,2%	4,1%	55,3%
firma/freelancer	131	15,3%	42,7%	2,3%	39,7%
teórico/modelo	148	22,3%	0,7%	0,0%	77,0%
survey/revisão	186	13,4%	2,7%	2,2%	81,7%

Percentuais na linha. $\chi^2 = 220{,}26$, $p < 0{,}001$, V de Cramér = 0,30. 'Indivíduo' ($n = 6$) agregado a firma/*freelancer*.

Cada um desses padrões reflete a própria lógica do arcabouço de Acemoglu e Restrepo (2019). Por construção, o índice de exposição mensura apenas a viabilidade técnica da automação de tarefas por máquinas, capturando o efeito-deslocamento sem considerar ganhos de produtividade, recomposição de demanda ou a criação de novas tarefas. A crítica de Arntz et al. (2017) a Frey e Osborne (2017) expõe a fragilidade dessa abordagem ao demonstrar que a heterogeneidade de tarefas dentro das ocupações reduz a parcela de empregos em risco de 47% para 9%. Contudo, a limitação conceitual aqui é ainda mais fundamental: mesmo uma medida perfeita de exposição tende a quantificar apenas o deslocamento potencial, e não o efeito líquido real.

No extremo oposto, os estudos focados em nível de firma comparam empresas adotantes e não adotantes. Nesses casos, as adotantes ganham produtividade, ampliam sua fatia de mercado e expandem a contratação, capturando o efeito-produtividade sob um arranjo de equilíbrio parcial. Entretanto, os ganhos de emprego de uma firma podem ocorrer em detrimento de suas concorrentes, impedindo que o saldo positivo em nível micro seja diretamente transposto para o setor – limitação formalizada por J. E. Bessen (2018) por meio da elasticidade da demanda. Cabe notar também a forte concentração geográfica desse desenho: 57 dos 131 estudos de firma no corpus analisam a China – predominantemente painéis de empresas listadas com adoção identificada via relatórios anuais. Desses estudos chineses, 56,1% encontram um efeito positivo (representando 32 das 56 pesquisas com sinal positivo nesse grupo), em contraste com 32,4% nos demais países.

[2]O V de Cramér foi empregado para mensurar a força da associação entre variáveis estritamente nominais — neste caso, cruzando o tipo de evidência metodológica e o sinal do efeito estimado sobre o emprego. Optou-se por essa métrica para testar empiricamente se a variação dos vereditos na literatura está sistematicamente associada à escolha do desenho de pesquisa.

Por fim, os modelos teóricos caracterizam-se pela ambiguidade intrínseca, visto que suas conclusões dependem estritamente da parametrização adotada. Essa categoria engloba também as pesquisas que não especificam a direção do impacto sobre o emprego[3]. A heterogeneidade de vereditos deriva, portanto, em parte das especificidades de cada estratégia metodológica. Contudo, a escolha do desenho de pesquisa explica apenas uma parcela modesta dessa variação[4]. A própria literatura macro e setorial – a mais numerosa da amostra – revela forte dispersão interna: 55,3% dos resultados são ambíguos, 25,3% negativos, 15,2% positivos e 4,1% nulos.

Essa convivência de achados no nível agregado corrobora a leitura fundamentada no desenho metodológico. De um lado, os estudos agregados mais citados encontram impactos nulos ou marginais sobre o emprego total (Acemoglu et al., 2022; Kauhanen & Rouvinen, 2025), resultado alinhado à projeção de Acemoglu (2025) de que os ganhos macroeconômicos da IA na próxima década serão modestos. De outro, efeitos negativos rápidos e mensuráveis manifestam-se em segmentos nos quais a substituição de tarefas é direta e a relação de trabalho é flexível, como o mercado *freelance* de redação e criação de imagens (Hui et al., 2024).

À primeira vista, a implicação metodológica parece evidente: a prevalência de resultados positivos ou negativos em um texto reflete mais a composição dos desenhos de pesquisa do que propriamente o efeito real da IA. Essa relação, contudo, é parcial. Conforme detalhado na próxima subseção, cerca de metade do aumento no sinal positivo entre os períodos persiste mesmo após o controle pelo tipo de evidência, observando-se um deslocamento das conclusões dentro dos próprios desenhos: nos estudos macro e setoriais, a fatia de resultados positivos subiu de 4,9% para 19,2%; nos de firma, avançou de 27,3% para 44,2%; e, nos modelos de exposição, a frequência de sinais negativos recuou de 62,2% para 42,9%.

7.4 Recomposição do corpus ou mudança de diagnóstico?

Se o sinal depende do desenho e a composição de desenhos mudou (Capítulo 6), é preciso perguntar quanto das diferenças pré/pós é mera recomposição. A Tabela 18 compara, para cada desfecho, a razão de chances bruta do período com a razão ajustada por tipo de evidência, objeto generativo, foco na China e qualidade.

Três padrões emergem. O crescimento do sinal *positivo* é, em cerca de metade, composição: a razão de chances cai de 5,12 para 2,49 quando se controla o tipo de estudo, pois a literatura recente tem quatro vezes mais estudos de firma, que são os que encontram efeitos positivos. O recuo do *deslocamento* é quase todo composição (de 0,27 para 0,52, já sem significância a 5%). Em contraste, a queda do sinal *negativo*, a alta da complementaridade, a queda da demanda agregada e o encurtamento do horizonte

[3]Ressalta-se que apenas 5 dos 816 estudos do corpus foram codificados como "não informado".

[4]O ajuste do modelo alcança um pseudo-R^2 de 0,07 para a probabilidade de sinal negativo e de 0,21 para o sinal positivo.

Tabela 18: Diferenças pré/pós brutas e ajustadas pela composição do corpus.

Desfecho	Pré	Pós	RC bruta	RC ajustada
Risco na alta qualificação	2,7%	13,6%	5,61 ($p = 0{,}0011$)	3,15 ($p = 0{,}0388$)
Sinal negativo	30,7%	21,6%	0,62 ($p = 0{,}0066$)	0,63 ($p = 0{,}0166$)
Sinal positivo	3,8%	16,8%	5,12 ($p < 0{,}001$)	2,49 ($p = 0{,}0174$)
Invoca deslocamento	95,4%	85,1%	0,27 ($p < 0{,}001$)	0,52 ($p = 0{,}0642$)
Invoca complementaridade	57,8%	73,0%	1,98 ($p < 0{,}001$)	1,73 ($p = 0{,}0023$)
Invoca demanda agregada	23,5%	12,4%	0,46 ($p < 0{,}001$)	0,59 ($p = 0{,}0140$)
Horizonte de longo prazo/projeção	56,7%	27,7%	0,29 ($p < 0{,}001$)	0,42 ($p < 0{,}001$)

RC do indicador "publicado em 2023+" em logit sem controles (bruta) e com controles para tipo de evidência, objeto IA generativa, país-foco China e *score* ≥ 4 (ajustada). Uma RC que se aproxima de 1 após o ajuste indica mudança de composição do corpus, e não mudança dentro dos tipos.

mantêm-se após o ajuste: são mudanças que ocorrem *dentro* de cada tipo de estudo. E o deslocamento do risco para a alta qualificação, embora atenuado, permanece.

Tabela 19: Perfis de mecanismos: participação por período e sinal associado.

Perfil de mecanismos	Pré	Pós	Negativo	Positivo	Ambíguo
Só deslocamento	18,9%	14,7%	67,2%	7,2%	23,2%
Deslocamento + compensação	77,2%	71,2%	19,2%	6,3%	73,0%
Só compensação	3,9%	14,1%	3,4%	64,8%	28,4%

Colunas Pré/Pós: participação do perfil no período ($\chi^2 = 17{,}61$, $p < 0{,}001$). Demais colunas: sinal sobre o emprego dentro de cada perfil. 'Compensação' = reinstalação, complementaridade ou demanda agregada.

A Tabela 19 reorganiza os quatro mecanismos em perfis e oferece a ponte mais direta entre a teoria e os resultados. O arcabouço de Acemoglu e Restrepo afirma que o efeito da tecnologia sobre o emprego é o saldo entre uma força de deslocamento e forças compensatórias. O corpus raciocina exatamente assim: dos estudos que invocam *apenas* o deslocamento, 67,2% concluem por efeito negativo; dos que invocam *apenas* forças compensatórias, 64,8% concluem por efeito positivo; e dos que invocam as duas coisas — três quartos do corpus —, 73,0% declaram o efeito ambíguo. A ambiguidade predominante da literatura não é indecisão: é a conclusão que se segue de reconhecer as duas forças sem dispor de magnitudes comparáveis para pesá-las, lacuna documentada na Tabela 10. O que muda entre os períodos é o crescimento do perfil "só compensação", de 3,9% para 14,1% dos estudos.

Dois traços dessa mudança merecem leitura crítica à luz do referencial. O primeiro é a assimetria entre complementaridade, que sobe quinze pontos, e reinstalação, que não se move. No arcabouço teórico as duas não são equivalentes: é a criação de *novas tarefas*, e não o ganho de produtividade nas existentes, que sustenta a demanda por trabalho no longo prazo (Acemoglu & Restrepo, 2019). Uma literatura que documenta cada vez mais

que a IA ajuda o trabalhador a fazer melhor o que já fazia, sem documentar na mesma proporção o surgimento de tarefas novas, descreve um cenário mais próximo da advertência de Acemoglu e Restrepo (2020b) e da "armadilha de Turing" de Brynjolfsson (2022) do que do otimismo que a palavra "complementaridade" sugere: ganhos de produtividade em tarefas existentes podem, com demanda inelástica, reduzir o emprego nessas mesmas tarefas.

O segundo traço é o recuo da demanda agregada, que cai pela metade. A literatura torna-se mais empírica e mais microeconômica, o que é um ganho de credibilidade, mas abandona justamente o canal do qual depende a resposta à pergunta agregada. Forma-se um ponto cego: sabe-se cada vez mais sobre o que acontece na firma que adota e cada vez menos sobre o que acontece na economia em que ela está.

Há, por fim, um resultado que o esquema de codificação desta revisão não consegue capturar e que a Introdução já insinuava. A evidência experimental mostra ganhos concentrados nos trabalhadores *menos* experientes dentro de uma mesma ocupação (Brynjolfsson et al., 2025; Noy & Zhang, 2023). Isso não é risco para a "baixa" nem para a "alta" qualificação entre ocupações: é *compressão* do retorno à experiência dentro delas. D. Autor (2024) constrói sobre essa evidência a conjectura de que a IA pode baratear a *expertise* e reabrir tarefas qualificadas a trabalhadores de qualificação intermediária, revertendo parte da polarização; Agrawal et al. (2019) já indicavam que automatizar a predição pode tanto substituir quanto valorizar o julgamento humano. A dicotomia alta/baixa qualificação, herdada do debate SBTC–RBTC, é possivelmente estreita demais para a IA generativa, e a categoria "ambos", estável em cerca de um terço do corpus, pode estar abrigando parte desse fenômeno. Uma futura rodada de extração deveria codificar a dimensão intraocupacional separadamente.

7.5 Quanto se pode confiar: validade e sensibilidade

Comparações múltiplas. O Capítulo 6 realiza nove testes pré/pós. A Tabela 20 aplica a correção de Holm: à exceção da reinstalação, que já não era significativa, todas as associações se mantêm.

Extração a partir do resumo. Como 86% dos estudos foram codificados a partir do resumo, a Tabela 21 compara-os com os lidos em texto completo. Para sinal, tipo de evidência e horizonte não há diferença detectável. Para a polarização há: o resumo deixa a dimensão sem classificar em 39,9% dos casos, contra 11,4% no texto completo, e, quando classifica, simplifica — a categoria "ambos" corresponde a 45,5% dos estudos lidos na íntegra e a 28,4% dos lidos pelo resumo. A variável central da revisão é, portanto, a mais afetada pela limitação de acesso ao texto completo, e as proporções de "baixa" e de "alta" qualificação estão provavelmente superestimadas em detrimento de "ambos". Não há, porém, indício de que o viés difira entre os períodos.

Tabela 20: Testes pré/pós com correção para comparações múltiplas.

Teste pré/pós	p bruto	p Holm	$< 0{,}05$
Polarização (distribuição completa)	$p = 0{,}0035$	$p = 0{,}0071$	sim
Sinal sobre o emprego	$p < 0{,}001$	$p < 0{,}001$	sim
Tipo de evidência	$p < 0{,}001$	$p < 0{,}001$	sim
Horizonte	$p < 0{,}001$	$p < 0{,}001$	sim
Risco na alta qualificação (H1)	$p < 0{,}001$	$p < 0{,}001$	sim
Deslocamento	$p < 0{,}001$	$p < 0{,}001$	sim
Reinstalação	$p = 0{,}5344$	$p = 0{,}5344$	não
Complementaridade	$p < 0{,}001$	$p < 0{,}001$	sim
Demanda agregada	$p < 0{,}001$	$p < 0{,}001$	sim

Correção de Holm sobre a família dos nove testes pré/pós do Capítulo 6.

Tabela 21: Validade da extração: estudos lidos pelo resumo vs. em texto completo.

Dimensão	n/a (resumo)	n/a (texto compl.)	V	χ^2
Polarização	39,9%	11,4%	0,15	$p = 0{,}0069$
Sinal sobre o emprego	0,6%	0,9%	0,03	$p = 0{,}8432$
Tipo de evidência	0,0%	0,0%	0,08	$p = 0{,}4102$
Horizonte	0,6%	0,0%	0,07	$p = 0{,}2278$

Compara os estudos extraídos do resumo com os lidos em texto completo: taxa de não classificação e associação entre a fonte e a distribuição das categorias.

Método comum. Todas as variáveis substantivas foram codificadas pelo mesmo modelo, a partir do mesmo texto e na mesma chamada. Associações entre elas — como a dos perfis de mecanismos com o sinal — podem estar infladas pela tendência do extrator a produzir codificações internamente coerentes. As associações com o ano de publicação, que é determinístico, não sofrem desse problema, e é nelas que se apoia o teste da hipótese central. A verificação humana amostral descrita na metodologia é o instrumento para dimensionar esse risco e permanece como a principal pendência do trabalho.

Cobertura da busca. A rede de citações do Capítulo **??** permite aferir a sensibilidade da busca contra um padrão externo: as referências mais citadas pelo próprio corpus. Das 46 referências com data elegível entre as 60 mais citadas, apenas 15 foram recuperadas pela busca (todas elas incluídas). Ficaram de fora trabalhos que o próprio referencial teórico trata como estruturantes — Frey e Osborne (2017), Acemoglu e Restrepo (2020a), Webb (2020), Felten et al. (2021), Eloundou et al. (2024), Noy e Zhang (2023) —, seja por usarem vocabulário ausente da *string* ("*computerisation*", "*robots*"), seja por circularem em periódicos de ciência geral ou como *working papers*, fora do alcance das bases. O corpus representa, assim, a literatura econômica *difusa* e indexada, e não a fronteira da disciplina. Isso não invalida a pergunta da revisão, que é sobre o enquadramento predominante no campo, mas delimita o que se pode concluir: os percentuais descrevem como a literatura ampla absorve e reproduz os diagnósticos, e a fronteira entra na análise

pelo referencial teórico e pela rede de co-citação. Como os trabalhos de fronteira ausentes sobre IA generativa apontam majoritariamente para a alta qualificação, o viés de cobertura opera, se tanto, *contra* a hipótese central.

7.6 Síntese: três proposições

A discussão permite condensar a resposta à pergunta da revisão em três proposições. Primeira: o diagnóstico da literatura mudou com a IA generativa, e mudou na direção prevista, mas a mudança acompanha o objeto tecnológico mais do que o calendário — a literatura sobre automação segue dizendo o que dizia, e a literatura sobre IA generativa diz outra coisa. O teste com a robótica como grupo de comparação confirma essa leitura e acrescenta duas ressalvas: o encurtamento do horizonte, o recuo da demanda agregada e o sinal mais positivo são tendências de época, comuns a todo o campo; e o novo diagnóstico apoia-se, por ora, em medidas de exposição e em revisões, não em efeitos observados. Segunda: essa diferença não contradiz o arcabouço de tarefas, e sim o confirma, pois o risco segue o conteúdo das tarefas que cada tecnologia executa; o que envelheceu não foi a teoria, e sim a identificação entre "rotineiro" e "automatizável". Terceira: a aparente divergência de vereditos sobre o emprego reflete sobretudo o que cada desenho mede, e o campo caminha para saber mais sobre a firma e menos sobre o agregado, justamente quando a pergunta relevante para a política pública é a agregada.

8 Considerações finais

Esta revisão perguntou se o diagnóstico da literatura econômica sobre o impacto da inteligência artificial no mercado de trabalho foi alterado pelo avanço da IA generativa. A resposta é afirmativa, mas exige três qualificações que constituem, elas próprias, os principais resultados do trabalho.

A primeira diz respeito ao *tamanho* da mudança. Entre os 816 estudos analisados, a fração que situa o risco nas ocupações de alta qualificação passa de 2,7% entre os publicados até 2022 para 13,6% entre os publicados de 2023 em diante, resultado que resiste a definições alternativas de período, à exclusão de subconjuntos do corpus e à correção para comparações múltiplas. O risco para a baixa qualificação, contudo, permanece o diagnóstico mais frequente nos dois períodos, o sinal predominante sobre o emprego continua ambíguo e o deslocamento segue sendo o mecanismo mais invocado. A hipótese de ruptura é confirmada em direção, mas não na forma forte de uma inversão do consenso.

A segunda diz respeito à *origem* da mudança, e é o achado mais importante. O deslocamento do risco acompanha o objeto tecnológico, e não o calendário. Entre os estudos sobre IA generativa, o risco para a alta qualificação é a categoria modal (48,5%); entre os estudos sobre robótica e automação, ele é residual e idêntico antes e depois do ChatGPT

(1,8% e 3,1%). Usada como grupo de comparação, a literatura de robótica permite separar dois conjuntos de mudanças: as específicas do objeto, que são o deslocamento do risco e parte da alta da complementaridade, e as de época, que são o encurtamento do horizonte, o recuo da demanda agregada e o sinal menos negativo, presentes nas duas literaturas e atribuíveis ao amadurecimento empírico do campo. A leitura teórica é que a abordagem de tarefas sai confirmada: o risco segue o conteúdo das tarefas que cada tecnologia executa. O que envelheceu não foi a teoria, e sim a identificação entre tarefa rotineira e tarefa automatizável.

A terceira diz respeito à *natureza* da evidência. O sinal que cada estudo atribui ao efeito sobre o emprego depende fortemente do desenho: estudos de exposição ocupacional tendem ao negativo, estudos de firma ao positivo, e modelos teóricos e revisões ao ambíguo. A aparente falta de convergência do campo é, em boa medida, um retrato da divisão de trabalho entre desenhos que capturam forças distintas do arcabouço de Acemoglu e Restrepo. Pela mesma razão, o novo diagnóstico sobre a IA generativa deve ser lido com cautela: os estudos que apontam a alta qualificação são exercícios de exposição, revisões e modelos, e nenhum é evidência de firma ou de nível agregado. A literatura de IA generativa encontra-se hoje onde a de robótica se encontrava há uma década, quando dispunha de índices de suscetibilidade e ainda não das estimativas causais que viriam a moderá-los.

As conclusões estão sujeitas a limitações discutidas ao longo do trabalho e aqui reunidas. A busca tem sensibilidade limitada: recuperou 15 das 46 referências com data elegível entre as mais citadas pelo próprio corpus, não alcança *working papers* e deixa de fora trabalhos de fronteira publicados em periódicos de ciência geral. O corpus representa, assim, a literatura econômica indexada e difusa, e não a fronteira da disciplina. Triagem, elegibilidade, extração e avaliação de qualidade foram realizadas por modelos de linguagem, e a verificação humana amostral prevista no protocolo é o instrumento que permite dimensionar o erro dessa cadeia. Apenas 14% dos estudos foram lidos em texto completo, e a variável central, a polarização, é justamente a mais afetada: fica sem classificação em 40% dos resumos e é simplificada quando classificada. As variáveis substantivas foram codificadas pelo mesmo modelo na mesma chamada, o que pode inflar associações entre elas; o teste da hipótese central, por apoiar-se no ano de publicação, é menos vulnerável a esse problema. O uso da robótica como grupo de comparação é uma análise *post hoc*, e o grupo de IA generativa é pequeno. Por fim, os testes estatísticos são exploratórios: descrevem associações num conjunto de estudos, não efeitos numa população.

Os resultados apontam quatro direções. A primeira é a produção de evidência causal sobre os efeitos da IA generativa no emprego, em nível de firma, de ocupação e de mercado de trabalho local, à semelhança do que a literatura de robótica construiu; sem ela, o diagnóstico de risco para a alta qualificação permanece uma hipótese sobre exposição. A segunda é a recuperação dos canais de equilíbrio geral: a literatura tornou-se mais empírica e mais microeconômica, mas a pergunta relevante para a política pública é

agregada, e a demanda agregada é hoje o mecanismo menos estudado. A terceira é a distinção entre complementaridade e reinstalação: documenta-se cada vez mais que a IA eleva a produtividade nas tarefas existentes, e muito menos que cria tarefas novas, e é da segunda que depende a demanda por trabalho no longo prazo. A quarta é a dimensão intraocupacional: a evidência de compressão do retorno à experiência não cabe na dicotomia entre alta e baixa qualificação, e revisões futuras deveriam codificá-la separadamente. Do ponto de vista metodológico, a experiência desta revisão recomenda que campos deriváveis de metadados nunca sejam delegados ao extrator automático e que a sensibilidade da busca seja aferida contra um conjunto de referência antes da triagem.

Referências

Acemoglu, D. (2002). Technical Change, Inequality, and the Labor Market. *Journal of Economic Literature*, *40*(1), 7–72. https://doi.org/10.1257/0022051026976

Acemoglu, D. (2025). The Simple Macroeconomics of AI. *Economic Policy*, *40*(121), 13–58. https://doi.org/10.1093/epolic/eiae042

Acemoglu, D., & Autor, D. (2011). Skills, Tasks and Technologies: Implications for Employment and Earnings. Em O. Ashenfelter & D. Card (Ed.), *Handbook of Labor Economics* (pp. 1043–1171, Vol. 4B). Elsevier.

Acemoglu, D., Autor, D., Hazell, J., & Restrepo, P. (2022). Artificial Intelligence and Jobs: Evidence from Online Vacancies. *Journal of Labor Economics*, *40*(S1), S293–S340. https://doi.org/10.1086/718327

Acemoglu, D., & Restrepo, P. (2018). The Race between Man and Machine: Implications of Technology for Growth, Factor Shares, and Employment. *American Economic Review*, *108*(6), 1488–1542. https://doi.org/10.1257/aer.20160696

Acemoglu, D., & Restrepo, P. (2019). Automation and New Tasks: How Technology Displaces and Reinstates Labor. *Journal of Economic Perspectives*, *33*(2), 3–30. https://doi.org/10.1257/jep.33.2.3

Acemoglu, D., & Restrepo, P. (2020a). Robots and Jobs: Evidence from US Labor Markets. *Journal of Political Economy*, *128*(6), 2188–2244. https://doi.org/10.1086/705716

Acemoglu, D., & Restrepo, P. (2020b). The Wrong Kind of AI? Artificial Intelligence and the Future of Labour Demand. *Cambridge Journal of Regions, Economy and Society*, *13*(1), 25–35. https://doi.org/10.1093/cjres/rsz022

Acemoglu, D., & Restrepo, P. (2022). Tasks, Automation, and the Rise in U.S. Wage Inequality. *Econometrica*, *90*(5), 1973–2016. https://doi.org/10.3982/ECTA19815

Agrawal, A., Gans, J. S., & Goldfarb, A. (2019). Artificial Intelligence: The Ambiguous Labor Market Impact of Automating Prediction. *Journal of Economic Perspectives*, *33*(2), 31–50. https://doi.org/10.1257/jep.33.2.31

Arntz, M., Gregory, T., & Zierahn, U. (2017). Revisiting the Risk of Automation. *Economics Letters*, *159*, 157–160. https://doi.org/10.1016/j.econlet.2017.07.001

Autor, D. (2024). *Applying AI to Rebuild Middle Class Jobs* (Working Paper N. 32140). National Bureau of Economic Research. https://doi.org/10.3386/w32140

Autor, D., Chin, C., Salomons, A., & Seegmiller, B. (2024). New Frontiers: The Origins and Content of New Work, 1940–2018. *The Quarterly Journal of Economics*, *139*(3), 1399–1465. https://doi.org/10.1093/qje/qjae008

Autor, D. H. (2015). Why Are There Still So Many Jobs? The History and Future of Workplace Automation. *Journal of Economic Perspectives*, *29*(3), 3–30. https://doi.org/10.1257/jep.29.3.3

Autor, D. H., & Dorn, D. (2013). The Growth of Low-Skill Service Jobs and the Polarization of the US Labor Market. *American Economic Review*, *103*(5), 1553–1597. https://doi.org/10.1257/aer.103.5.1553

Autor, D. H., Dorn, D., & Hanson, G. H. (2015). Untangling Trade and Technology: Evidence from Local Labour Markets. *The Economic Journal*, *125*(584), 621–646. https://doi.org/10.1111/ecoj.12245

Autor, D. H., Katz, L. F., & Kearney, M. S. (2006). The Polarization of the U.S. Labor Market [Papers and Proceedings]. *American Economic Review*, *96*(2), 189–194. https://doi.org/10.1257/000282806777212620

Autor, D. H., Katz, L. F., & Kearney, M. S. (2008). Trends in U.S. Wage Inequality: Revising the Revisionists. *The Review of Economics and Statistics*, *90*(2), 300–323. https://doi.org/10.1162/rest.90.2.300

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The Skill Content of Recent Technological Change: An Empirical Exploration. *The Quarterly Journal of Economics*, *118*(4), 1279–1333. https://doi.org/10.1162/003355303322552801

Bessen, J., Goos, M., Salomons, A., & van den Berge, W. (2025). What Happens to Workers at Firms that Automate? *The Review of Economics and Statistics*, *107*(1), 125–141. https://doi.org/10.1162/rest_a_01284

Bessen, J. E. (2018). *AI and Jobs: The Role of Demand* (NBER Working Paper N. 24235). National Bureau of Economic Research. https://doi.org/10.3386/w24235

Brynjolfsson, E. (2022). The Turing Trap: The Promise & Peril of Human-Like Artificial Intelligence. *Daedalus*, *151*(2), 272–287. https://doi.org/10.1162/daed_a_01915

Brynjolfsson, E., Li, D., & Raymond, L. (2025). Generative AI at Work [Circulou como NBER Working Paper 31161 em 2023]. *The Quarterly Journal of Economics*, *140*(2), 889–942. https://doi.org/10.1093/qje/qjae044

Brynjolfsson, E., & McAfee, A. (2014). *The Second Machine Age: Work, Progress, and Prosperity in a Time of Brilliant Technologies*. W. W. Norton.

Brynjolfsson, E., Mitchell, T., & Rock, D. (2018). What Can Machines Learn, and What Does It Mean for Occupations and the Economy? *AEA Papers and Proceedings*, *108*, 43–47. https://doi.org/10.1257/pandp.20181019

Dauth, W., Findeisen, S., Suedekum, J., & Woessner, N. (2021). The Adjustment of Labor Markets to Robots. *Journal of the European Economic Association*, *19*(6), 3104–3153. https://doi.org/10.1093/jeea/jvab012

Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2024). GPTs are GPTs: Labor Market Impact Potential of LLMs. *Science*, *384*(6702), 1306–1308. https://doi.org/10.1126/science.adj0998

Felten, E. W., Raj, M., & Seamans, R. (2018). A Method to Link Advances in Artificial Intelligence to Occupational Abilities. *AEA Papers and Proceedings*, *108*, 54–57. https://doi.org/10.1257/pandp.20181021

Felten, E. W., Raj, M., & Seamans, R. (2021). Occupational, Industry, and Geographic Exposure to Artificial Intelligence: A Novel Dataset and Its Potential Uses. *Strategic Management Journal*, *42*(12), 2195–2217. https://doi.org/10.1002/smj.3286

Fontanelli, L., Calvino, F., Criscuolo, C., Nesta, L., & Verdolini, E. (2025). Human after all: Occupations at the core of AI adoption. *Labour Economics*, *95*, 102754. https://doi.org/10.1016/j.labeco.2025.102754

Frey, C. B., & Osborne, M. A. (2017). The Future of Employment: How Susceptible Are Jobs to Computerisation? [Circulou como working paper da Oxford Martin School em 2013]. *Technological Forecasting and Social Change*, *114*, 254–280. https://doi.org/10.1016/j.techfore.2016.08.019

Gallen, T., & Kim, S. (2025). Automation and Heterogeneous Earnings Dynamics. *Economics Letters*, *255*, 112518. https://doi.org/10.1016/j.econlet.2025.112518

Goldin, C., & Katz, L. F. (2008). *The Race between Education and Technology*. Belknap Press of Harvard University Press.

Goller, D., Gschwendt, C., & Wolter, S. C. (2025). This time it's different – Generative artificial intelligence and occupational choice. *Labour Economics*, *95*, 102746. https://doi.org/10.1016/j.labeco.2025.102746

Goos, M., & Manning, A. (2007). Lousy and Lovely Jobs: The Rising Polarization of Work in Britain. *The Review of Economics and Statistics*, *89*(1), 118–133. https://doi.org/10.1162/rest.89.1.118

Goos, M., Manning, A., & Salomons, A. (2014). Explaining Job Polarization: Routine-Biased Technological Change and Offshoring. *American Economic Review*, *104*(8), 2509–2526. https://doi.org/10.1257/aer.104.8.2509

Graetz, G., & Michaels, G. (2018). Robots at Work. *The Review of Economics and Statistics*, *100*(5), 753–768. https://doi.org/10.1162/rest_a_00754

Hémous, D., Olsen, M., Zanella, C., & Dechezleprêtre, A. (2025). Induced Automation Innovation: Evidence from Firm-Level Patent Data. *Journal of Political Economy*, *133*(6), 1975–2028. https://doi.org/10.1086/734778

Hui, X., Reshef, O., & Zhou, L. (2024). The Short-Term Effects of Generative Artificial Intelligence on Employment: Evidence from an Online Labor Market. *Organization Science*, *35*(6), 1977–1989. https://doi.org/10.1287/orsc.2023.18441

Katz, L. F., & Murphy, K. M. (1992). Changes in Relative Wages, 1963–1987: Supply and Demand Factors. *The Quarterly Journal of Economics*, *107*(1), 35–78. https://doi.org/10.2307/2118323

Kauhanen, A., & Rouvinen, P. (2025). Assessing Early Labour Market Effects of Generative AI: Evidence from Population Data. *Applied Economics Letters*, 1–4. https://doi.org/10.1080/13504851.2025.2513973

Keynes, J. M. (1930). Economic Possibilities for our Grandchildren [Publicado originalmente em *The Nation and Athenaeum*, out. 1930; reimpresso na coletânea de 1931]. Em *Essays in Persuasion*. Macmillan.

Korinek, A. (2023). *Language Models and Cognitive Automation for Economic Research* (NBER Working Paper N. 30957). National Bureau of Economic Research. https://doi.org/10.3386/w30957

Krueger, A. B. (1991, agosto). *How Computers Have Changed the Wage Structure: Evidence from Microdata, 1984–89* [mimeo], Princeton University.

Leontief, W. (1983). Technological Advance, Economic Growth, and the Distribution of Income. *Population and Development Review*, *9*(3), 403–410.

Lordan, G., & Neumark, D. (2018). People versus Machines: The Impact of Minimum Wages on Automatable Jobs. *Labour Economics*, *52*, 40–53. https://doi.org/10.1016/j.labeco.2018.03.006

Moll, B., Rachel, L., & Restrepo, P. (2022). Uneven Growth: Automation's Impact on Income and Wealth Inequality. *Econometrica*, *90*(6), 2645–2683. https://doi.org/10.3982/ECTA19417

Nie, Y., & Xue, K. (2026). How Artificial Intelligence Penetration Affects Workers' Job Quality? Empirical Evidence from China. *Telecommunications Policy*, *50*(6), 103229. https://doi.org/10.1016/j.telpol.2026.103229

Noy, S., & Zhang, W. (2023). Experimental Evidence on the Productivity Effects of Generative Artificial Intelligence. *Science*, *381*(6654), 187–192. https://doi.org/10.1126/science.adh2586

Semtner, A., Dzator, J., & Nadolny, A. (2025). Is No (Soft) Skill Left Behind? Do Soft Skills Enable Job Mobility. *Applied Economics*, *57*(33), 4897–4915. https://doi.org/10.1080/00036846.2024.2364103

Sun, H., & Gao, G. (2025). The Impact of Intelligent Automation on Subjective Well-Being and Job Satisfaction: A Comparison between Standard and Nonstandard

Employment. *China Economic Review*, *94*, 102524. https://doi.org/10.1016/j.chieco.2025.102524

Tinbergen, J. (1974). Substitution of Graduate by Other Labour. *Kyklos*, *27*(2), 217–226. https://doi.org/10.1111/j.1467-6435.1974.tb01903.x

Tinbergen, J. (1975). *Income Distribution: Analysis and Policies*. North-Holland.

Wang, L., Zhao, H., Cao, Z., & Dong, Z. (2024). Artificial Intelligence and Intergenerational Occupational Mobility. *Journal of Asian Economics*, *90*, 101675. https://doi.org/10.1016/j.asieco.2023.101675

Webb, M. (2020). The Impact of Artificial Intelligence on the Labor Market [Working paper, Stanford University]. https://doi.org/10.2139/ssrn.3482150

Yakymovych, Y. (2025). Consequences of Job Loss for Routine Workers. *Empirical Economics*, *69*(6), 3967–3992. https://doi.org/10.1007/s00181-025-02827-9